Jonas Helmut Wilinski

Eine Anwendung des Reinforcement Learning auf biologische neuronale Netze zur Regelung dynamischer Systeme am Beispiel des inversen Pendels

Bachelor-Arbeit

Stand: 07. September 2018

Jonas Helmut Wilinski

Eine Anwendung des Reinforcement Learning auf biologische neuronale Netze zur Regelung dynamischer Systeme am Beispiel des inversen Pendels

Bachelor-Arbeit

Prüfer: Prof. Dr.-Ing habil. Thomas Meurer, Dr. Alexander Schaum
Abgabedatum: 07. September 2018

Inhaltsverzeichnis

Abstract und Kurzfassung

Abstract

This bachelor thesis implements a way to achieve a reliable and stable control of a dynamic system through approaches of reinforcement learning. As an example for a neuronal network, the „Touch Withdrawal Circuit“ of the worm *C. Elegans* is examined in great detail and the structures are transformed into a simulator. As a simulation environment, the inverted pendulum is being used with one degree of freedom (1 DOF). To simulate the neural network and guarantee stabilization of the inverted pendulum, a simulator is being developed and implemented using the programming language `Python`. Using the well known Leaky Integrate and Fire model, simulation of internal neural dynamics and processing information within the network is made possible. Furthermore, parameters of the network are found using reinforcement learning algorithms and applied to the environment `CartPole_v0` from OpenAI Gym. The results of this work show, that it is possible to implement a functional simulator for biological neural networks and to link it with methods of reinforcement learning. After computing multiple simulations, suitable parameters for the network, which ensure stable control of the inverse pendulum, are found. An application to other simulation environments or with similar neural networks is also possible due to the modular structure of the simulator.

Kurzfassung

Ziel dieser Bachelorarbeit ist es, durch Ansätze des Reinforcement Learning, sowie unter Nutzung biologischer neuronaler Netze, eine zuverlässige und stabile Regelung eines dynamischen Systems zu erzielen. Als neuronales Netz wird der sog. „Touch Withdrawal Circuit“ des Wurms *C. Elegans* detailliert untersucht und die Strukturen in einen Simulator überführt. Als Simulationsumgebung wird das inverse Pendel mit einem Freiheitsgrad gewählt. Um das o.g. neuronale Netz zu simulieren und die Regelung auf das inverse Pendel zu übertragen, wird ein Simulator in der Programmiersprache `Python` entwickelt und implementiert. Dieser nutzt das bekannte Leaky Integrate and Fire Modell, um die neuronale Dynamik zu simulieren und Prozesse innerhalb des Netzwerkes darzustellen. Parameter des Netzwerkes werden durch Algorithmen des *Reinforcement Learning* gefunden und auf die Umgebung `CartPole_v0` von OpenAI Gym angewendet. Das Ergebnis dieser Arbeit zeigt, dass es möglich ist, einen funktionsfähigen Simulator für biologische neuronale Netze zu implementieren und diesen mit Methoden des *Reinforcement Learning*

zu koppeln. Durch rechenintensive Simulationen wurden geeignete Parameter für das Netzwerk gefunden, welche eine stabile Regelung des inversen Pendels gewährleisten. Eine Anwendung auf weitere Simulationsumgebungen oder mit ähnlichen neuronalen Netzen ist durch den modularen Aufbau des Simulators ebenfalls möglich.

Kapitel 1
Einleitung

Diese Arbeit beschäftigt sich mit Bereichen des Reinforcement Learning und der Anwendung biologischer neuronaler Netze auf Probleme der Regelungstechnik.

Hierzu wird als Basis die Arbeit von Lechner et al. „Worm-level Control through Search-based Reinforcement Learning“ [9] und „Neuronal Circuit Policies“ [10] herangezogen. Anders als herkömmliche neuronale Netze, welche meist künstlich erzeugt und angewendet werden, findet in dieser Arbeit ein biologisches Netz des Wurms *C. Elegans* Anwendung. Dieses Netz wurde bereits durch verschiedene Artikel [2] [6] [20] untersucht und vorgestellt. Um es zu simulieren, wird auf das *Leaky Integrate and Fire (LIF)* - Modell verwiesen, welches eine gute Berechnungsgrundlage für Prozesse innerhalb biologischer neuronaler Netze bietet. Zur Berechnung der neuronalen Dynamik müssen charakteristische Größen innerhalb des Netzes berechnet werden:

- Membranpotential U_i einer Nervenzelle und
- Anliegende Ströme I_i aus Sensorneuronen, Synapsen und Gap-Junctions.

Um die Informationsverarbeitung innerhalb des Netzes zu nutzen, werden sog. Sensor- und Motor-Neuronen definiert. Sensor-Neuronen nehmen Größen aus der gegebenen Umwelt auf und übersetzen diese in ein verständliches Format. In diesem Fall werden Größen auf einen Aktionsbereich von $A \in [-70\ \text{mV}, -20\ \text{mV}]$ übersetzt. Gleichzeitig können Motor-Neuronen den genannten Aktionsbereich A bspw. auf translatorische Größen anwenden.

Aufgrund des komplexen Berechenbarkeitsmodells biologischer neuronaler Netze müssen für alle eingesetzten Nervenzellen, Synapsen und Gap-Junctions Parameter gefunden werden, welche eine gute und stabile Simulation der gegebenen Umwelt gewährleisten. Hier wird auf die Methode des *Reinforcement Learning* verwiesen. Durch Generierung von zufälligen Parametern anhand einer Gleichverteilung mit gegebenen Grenzen wird eine Vielzahl an Simulationen ausgeführt. Ein Belohnungssystem gibt Aufschluss über die Güte der eingesetzten Parameter. Besonders gute Parametersätze werden nach Ablauf der Simulationszeit gespeichert. Im weiteren Verlauf wird auch auf die Methode der genetischen Algorithmen hingewiesen, welche einen evolutionären Ansatz verfolgt und die Grenzen der genannten Gleichverteilung für Parameter zielgerichtet einschränken kann. Durch eine nachgelagerte Optimierung des Netzwerkes mit Gewichtung der Synapsen und Gap-Junctions werden stabile und reproduzierbare Simulationsergebnisse erzielt.

Als Simulationsumgebung wird das inverse Pendel genutzt. Das sog. `CartPole_v0` wird aus dem bereits bestehenden Framework OpenAI Gym [1] importiert. Das inverse Pendel kann im

Lernprozess stabilisiert werden, entsprechende Parameter sowie Animationen sind in Anhang B und C zu finden.

Letztlich wird eine Zusammenfassung sowie ein ausführlicher Ausblick über die Ergebnisse dieser Arbeit präsentiert.

Kapitel 2
Grundlagen der neuronalen Netze

Im Laufe der Zeit wurde das Konstrukt der neuronalen Netze aus der Biologie heraus erforscht und stark abstrahiert. Dies ermöglicht den Einsatz neuartiger Maschinen und Algorithmen zum Lösen verschiedener Problemstellungen. Um die Performance der klassischen Automaten bzw. Rechenmaschinen zu testen, werden einige Berechenbarkeitsmodelle vorgestellt. Die einzigartige Umsetzung in Netzwerken neuronaler Nervenzellen ermöglicht es, hochkomplexe Aufgaben selbst bei niedrigen Taktfrequenzen durch hohe Parallelität zu bewältigen. Im weiteren Verlauf wird auf die Notation und Beschaffenheit neuronaler Netze eingegangen.

Dieser Abschnitt der Bachelorarbeit lehnt sich besonders an die ersten Kapitel der folgenden Bücher an: *R.Rojas - Theorie der neuronalen Netze* [14] und *Gerstner et al. - Neuronal Dynamics* [21]. Weitere Fachartikel werden im Laufe des Kapitels genannt.

2.1 Grundlegende Berechenbarkeitsmodelle

Im Bereich der Berechenbarkeitstheorie (oder auch Rekursionstheorie) werden Probleme auf die Realisierbarkeit durch ein mathematisches Modell einer Maschine bzw. einem Algorithmus untersucht und kategorisiert. Diese Theorie entwickelt sich aus der mathematischen Logik und der theoretischen Informatik. Neuronale Netze bieten hier eine alternative Formulierung der Berechenbarkeit neben den bereits etablierten Modellen an. Es existieren die folgenden fünf Berechenbarkeitsmodelle, welche durch einen mathematischen oder physikalischen Ansatz versuchen, ein gegebenes Problem zu lösen:

- Das mathematische Modell

  Die Frage nach der Berechenbarkeit wird in der Mathematik durch die zur Verfügung stehenden Mittel dargestellt. So sind primitive Funktionen und Kompositionsregeln offensichtlich zu berechnen, komplexe Funktionen, welche sich nicht durch primitive Probleme darstellen lassen, jedoch nicht. Durch die *Church-Turing-These* [18] wurden diese wie folgt abgegrenzt: „Die berechenbaren Funktionen sind die allgemein rekursiven Funktionen.“

- Das logisch-operationelle Modell (Turing-Maschine)

  Durch die Turing Maschine [18] war es möglich, neben der mathematischen Herangehensweise an Berechenbarkeitsprobleme, eine mechanische Methode einzusetzen. Die Turing-Maschine nutzte ein langes Speicherband, welches nach gewissen Regeln schrittweise manipuliert wurde. So konnte sie sich in einer bestimmten Anzahl von Zuständen befinden und nach entsprechenden Regeln verfahren.

- Das Computer-Modell

  Kurz nach dem bahnbrechenden Erfolg von Turing und Church wurden viele Konzepte für elektrische Rechenmaschinen entworfen. Konrad Zuse entwickelte in Berlin ab dem Jahr 1938 Rechenautomaten, die jedoch nicht in der Lage waren, alle allgemein rekursiven Funktionen zu lösen. Der Mark I, welcher um 1948 an der Manchester Universität gebaut wurde, war der erste Computer, der in der Lage war, alle rekursiven Funktionen zu lösen. Er verfügte über die damals etablierte Von-Neumann-Architektur [12] und wurde von Frederic Calland Williams erbaut.

- Das Modell der Zellautomaten

  John von Neumann arbeitete darüber hinaus ebenfalls an dem Modell der Zellautomaten, welches eine hoch-parallele Umgebung bot. Die Synchronisation und Kommunikation zwischen den Zellen stellte sich jedoch als herausfordernde Problemstellung heraus, die nur durch bestimmte Algorithmen gelöst werden konnte. Eine solche Umgebung liefert, wenn richtig umgesetzt, selbst bei geringen Taktfrequenzen eine enorme Rechenleistung dank Multiprozessorarchitektur.

- Das biologische Modell (neuronale Netze)

  Neuronale Netze heben sich von den vorher beschriebenen Methoden ab. Sie sind nicht sequentiell aufgebaut und können, anders als Zellautomaten, eine hierarchische Schichtenstruktur besitzen. Die Übertragung von Informationen ist daher nicht nur zum Zellnachbarn, sondern auch im ganzen Netzwerk möglich. Es werden im neuronalen Netz keine Programme (wie in Rechenmaschinen üblich) gespeichert, sondern durch die sog. Netzparameter erlernt. Dieser Ansatz wurde früher durch mangelnde Rechenleistung der konventionellen Computer nicht weiter verfolgt. Heute erfahren wir immer mehr den Aufwind neuester Lernalgorithmen und Frameworks, die das Arbeiten im Bereich *Deep Learning*, *Artificial Intelligence* und adaptives Handelns signifikant unterstützen und beschleunigen. Weitergehend ist man in der Lage, auf dem Gebiet der Biologie Nervensysteme zu analysieren und dabei von Millionen Jahren der Evolution zu profitieren. So können verschiedene neuronale Netze genauestens beschrieben und simuliert werden.

2.2 Grundlagen der biologischen Nervenzelle

Zellen, wie sie in jeder bekannten Lebensform auftreten, sind weitestgehend erforscht und gut verstanden. Wie alle Zellen im Körper bestehen sie (stark vereinfacht) aus einer Zellmembran, einem Zellskelett und einem Zellkern, welcher die chromosomale DNA und somit die Mehrzahl an Genen enthält. Sie treten im menschlichen Körper in verschiedenen Größen und mit unter-

schiedlichen Eigenschaften auf. Neuronale Nervenzellen wurden über die Evolution dahingehend ausgeprägt, dass sie Informationen empfangen, verarbeiten und entsenden können. Wie in Abbildung 2.1 zu sehen, besteht eine Nervenzelle aus drei Bestandteilen: *Dendrit, Soma und Axon.*

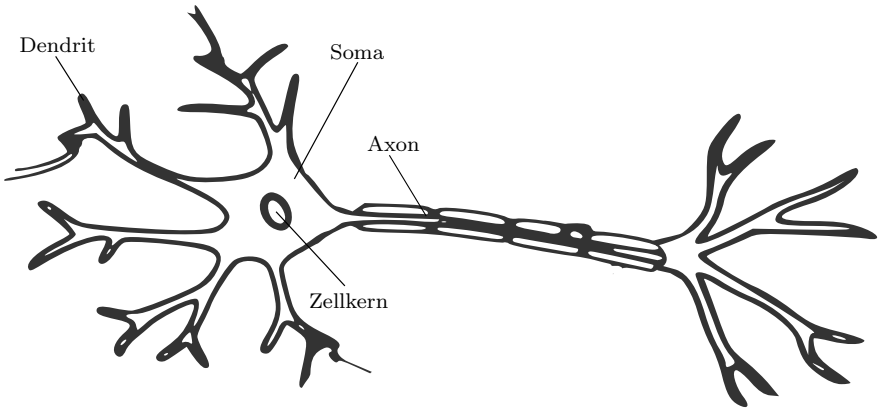

Abb. 2.1: Schematische Darstellung einer Nervenzelle, bestehend aus Dendrit, Soma und Axon (`https://pixabay.com/de/gehirn-neuron-nerven-zelle-2022398` mit eigenen Erweiterungen - Zugriff 06.08.2018, 16:00h).

- Dendrit:

  Der Dendrit (altgr.: „Baum“) dient der Reizaufnahme in der Nervenzelle. Gelangen durch andere Nervenzellen Spannungsspitzen durch vorhandene Synapsen an den Dendriten, leitet dieser die Signale an das Soma weiter.

- Soma:

  Das Zellsoma bezeichnet den allgemeinen Körper der Zelle. Es umfasst den plasmatischen Bereich um den Zellkern, ohne die Zellfortsätze wie Dendriten und Axon. Hier findet der Hauptteil des Stoffwechsels statt. Alle ankommenden Signale aus den Dendriten werden integrierend verarbeitet und ziehen eine Änderung des Membranpotentials mit sich. Empfangene Signale können erregend oder hemmend auf den Summationsprozess wirken (siehe Abschnitt 2.3 und Kapitel 3). Überschreitet das Membranpotential einen gewissen Schwellwert, so reagiert das Soma und erzeugt einen Spannungspuls, welcher an das Axon gegeben wird.

- Axon:

  Das Axon (altgr. ’Achse’) ist ein Nervenzellfortsatz, welcher für die Weiterleitung der Signale von dem Soma an die Synapsen und damit an andere Nervenzellen verantwortlich ist.

Verbunden sind Nervenzellen durch sog. Synapsen, welche den Informationsfluss gewährleisten. Der Informationsfluss geschieht in Synapsen größtenteils chemisch. Bei einem ankommenden Aktionspotential werden Neurotransmitter aus der Zelle ausgeschüttet, die für einen Ionentransport verantwortlich sind. Nach Übertragung der chemischen Stoffe über den Synapsenspalt werden diese wieder in ein elektrisches Potential umgewandelt. Diese Synapsen treten zwischen benachbarten Nervenzellen bzw. auf kurzer Distanz auf. Elektrische Synapsen dienen als Kon-

taktstellen und ermöglichen eine Übertragung von Ionen und kleineren Molekülen von einer Zelle zur anderen teils über weitere Distanzen. Die Signalübertragung entfernter Nervenzellen wird somit synchronisiert. Man bezeichnet sie als „Gap-Junctions“. Im weiteren Verlauf dieser Arbeit werden Synapsen nach Abbildung 2.2 dargestellt.

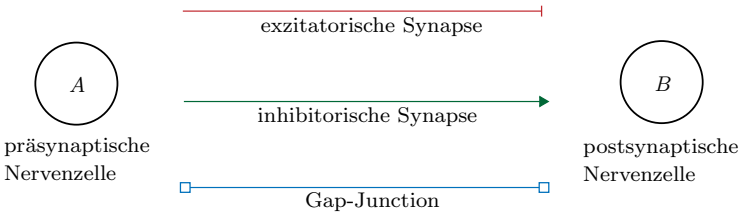

Abb. 2.2: Darstellung von verschiedenen Synapsen-Typen.

Bei chemischen Synapsen ist zwischen exzitatorischen und inhibitorischen Synapsen zu unterscheiden. Erstgenannte agieren als erregende Synapsen und übertragen das Aktionspotential mit positivem Vorzeichen an die postsynaptische Nervenzelle. Inhibitorische Synapsen sind hingegen hemmender Natur und führen das Potential mit einem negativen Vorzeichen, sodass es entsprechend negativ gewichtet in den Integrationsprozess der postsynaptischen Nervenzelle eingeht.

2.3 Biologische neuronale Netze

Funktionsweisen neuronaler Netze sind bereits gut erforscht und modelliert worden. Besonders das Nervensystem des Wurms *C. Elegans* [2] ist das bisher am besten verstandene Konstrukt in diesem Bereich der neuronalen Forschung. In dieser Arbeit wird insbesondere auf den sog. *Touch-Withdrawal-Circuit* eingegangen und versucht, eine Implementierung zu schaffen, welche ein dynamisches System erfolgreich regeln kann.

Ausgangspunkt ist das bereits von Lechner et al. [9] grafisch dargestellte neuronale Netz des *C. Elegans*, welches den Berührungs-Reflex des Wurms modelliert. Wird der Wurm einem äußeren Stimulus (bspw. einer Berührung) ausgesetzt, so schnellt er zurück.

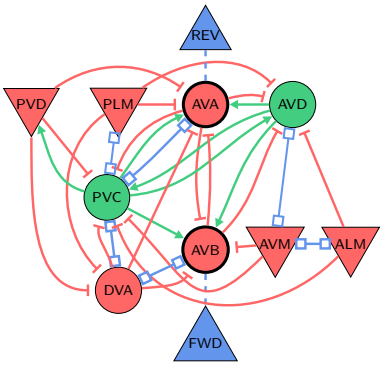

Abb. 2.3: *TW-Neuronal-Circuit* nach Lechner et al. [9].

Die Sensor-Neuronen PVD, PLM, AVM und ALM stellen Rezeptoren dar und reagieren auf Berührung. Sie transduzieren in diesem Fall die Berührung in eine neuronal vergleichbare Form als Aktionspotential und übermitteln diese Information durch die gegebenen Synapsen inhibitorisch oder exzitatorisch an die verbundenen internen Nervenzellen. Dieses Potential beträgt je nach gegebener Intensität der Berührung zwischen -70 mV (Ruhespannung - keine Berührung) und -20 mV (Spike-Potential - maximale Berührungsintensität) und bildet den Aktionsraum $A \in [-70\text{ mV}, -20\text{ mV}]$. Die genannten Sensor-Neuronen lassen sich so beliebig einsetzen und stellen bspw. im Experiment des inversen Pendels positive und negative Observationsgrößen dar. Eine beispielhafte Belegung ist die Folgende:

Umgebungsvariable	*Typ*	*Posivite Sensor-Neurone*	*Negative Sensor-Neurone*
φ	Observation	PLM	AVM
$\dot{\varphi}$	Observation	ALM	PVD
a	Action	FWD	REV

Interneuronen, wie PVC, AVD, DVA, AVA und AVB sind direkt mit Sensor-Neuronen sowie untereinander durch Synapsen und Gap-Junctions verbunden. In jeder internen Nervenzelle findet ein Integrationsprozess der jeweiligen anliegenden Ströme aus Stimulus $I_{Stimuli}$, anderen chemischen Synapsen I_{Syn} und Gap-Junctions I_{Gap} statt. Durch das *LIF* - Modell kann das Membranpotential durch anliegende Ströme zum nächstgelegenen Zeitpunkt bestimmt und ein mögliches Feuer-Event vorhergesagt werden. Eine Nervenzelle feuert ein Signal, wenn das Membranpotential einen Schwellwert („Threshold“) $\vartheta = -20$ mV erreicht hat. Neurotransmitter werden freigelassen und ein Informationsfluss findet statt.

Um nun den Reflex des Wurms *C. Elegans* umzusetzen, benötigt es noch zwei Motor-Neuronen. Diese sind dafür zuständig, einen Befehl in Form eines Feuer-Signals an gewisse Muskelgruppen zu übersetzen, damit diese bewegt werden. In dem behandelten Experiment bedient das Inter-Neuron AVA das Motor-Neuron REV, welches für eine Rückwärtsbewegung steht, analog das Inter-Neuron AVB das Motor-Neuron FWD, welches eine Vorwärtsbewegung initiiert.

Dieser Kreislauf bildet somit ein in sich geschlossenes System mit vier Eingängen und zwei Ausgängen und formt ein lernfähiges neuronales Netz. Um Umgebungsgrößen für das Netz entsprechend zu übersetzen, wird in Abschnitt 3.2 durch die Gleichung (3.10) eine Übersetzungsvorschrift eingeführt.

2.4 Symmetrische neuronale Netze

Wie in [20] bereits thematisiert, wurde in Abbildung 2.3 lediglich eine Hälfte des symmetrischen neuronalen Netzes des Wurms *C. Elegans* beschrieben. Wie im menschlichen Gehirn besteht das Netzwerk aus zwei Hälften, welche zusammenwirken und bei gegebenen Sensor-Input eine Aktion wählen. Eine erweiterte Analyse des Netzwerks, besonders mit den berechneten Gewichten der einzelnen Synapsen, ergibt, dass das gegebene Netz von Lechner et al. unsymmetrisch scheint. Die Nervenzelle *DVA*, welche als Synchronisationszelle zwischen beiden Netzwerkhälften dienen soll, taucht im gegebenen Netz als unsymmetrische Komponente auf und scheint gewisse Sensor-

Inputs ungleichmäßig zu gewichten. Im Zuge dessen wird ein eigenes, symmetrisches neuronales Netz entwickelt, welches zum einen symmetrischer Natur ist, zum anderen manche Synapsen und Gap-Junctions nicht berücksichtigt, da diese nicht zielführend für das gegebene Problem erschienen. Spätere Simulationen bestätigten diese Annahmen, indem durch Gewichtung der Synapsen und Gap-Junctions manche Verbindungen ein verschwindend geringes Gewicht erhielten.

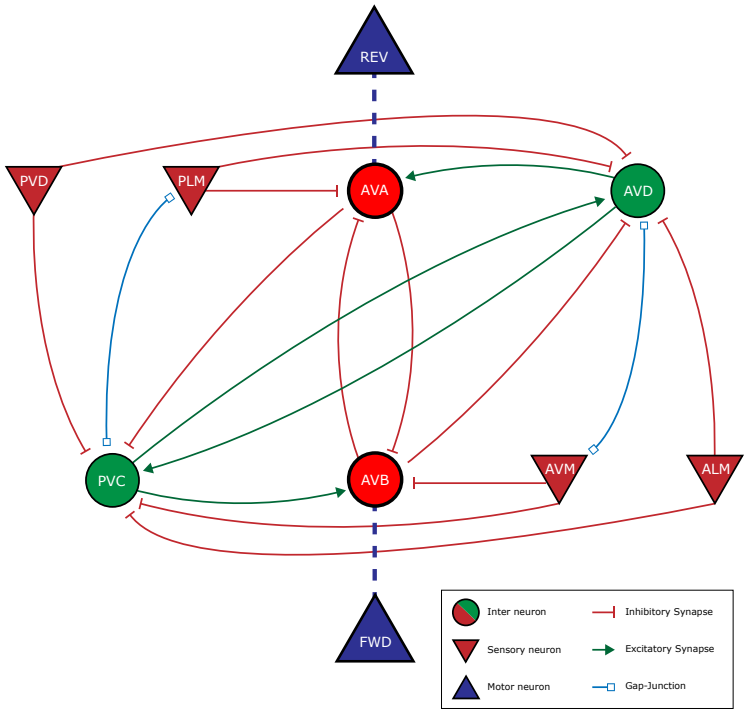

Abb. 2.4: Eigenes symmetrisches neuronales Netz des *TW-Circuits*.

Das in Abbildung 2.4 dargestellte, symmetrische neuronale Netz des *Touch Withdrawal Circuit* wird für alle weiteren Analysen und Simulationsläufe verwendet. Die genaue Umsetzung wird in Kapitel 5 weiter erläutert.

Kapitel 3

Leaky Integrate and Fire und simulative Modelle neuronaler Netze

Um biologische neuronale Netze zu simulieren und nutzbar zu machen, bedarf es verschiedener Modelle und Algorithmen. Dieses Kapitel stellt das *Leaky Integrate and Fire (LIF)* - Modell vor, welches zur Berechnung des Membranpotentials einer internen Nervenzelle dient. Da es sich hier um eine lineare Differenzialgleichung erster Ordnung handelt, werden darüber hinaus numerische Berechnungsmethoden vorgestellt, welche ebenfalls implementiert werden. Weiterhin wird auf die Berechnung der Synapsenströme und Übersetzung der Sensorpotentiale eingegangen und ein simulatives Modell des neuronalen Netzes vorgestellt.

3.1 Herleitung des Leaky Integrate and Fire - Modells

Grundsätzlich wird in der Natur beobachtet, dass die neuronale Dynamik als Summationsprozess, gefolgt von einer kurzfristigen Entladung des Aktionspotentials beschrieben werden kann. Die Entladung erfolgt hierbei immer ab einem gewissen Wert, welcher als Schwellwert ϑ beschrieben wird. Bei Überschreitung dieses Grenzwertes „feuert“ die Nervenzelle und Informationen gelangen über Synapsen und Gap-Junctions zu nahegelegenen Neuronen.

Um dieses Verhalten zu modellieren, wird der Zellkern genauer betrachtet. Dieser ist mit einer Zellmembran umgeben, welche als guter Isolator dient. Bei anliegenden Strömen $I_{Stimuli}$, I_{Syn} oder I_{Gap} wird die elektrische Ladung $q = \int I(t')dt'$ die Membran aufladen. Die Zellmembran handelt analog eines Kondensators mit Kapazität C_m. Da jedoch in der Natur kein perfekter Kondensator existiert, verliert die Zellmembran über die Zeit minimal elektrische Ladung. Daher wird dem Kondensator im Ersatzschaltbild ein Leckwiderstand R parallel geschaltet. Um das beobachtete Ruhepotential U_{Leak} nach einem Feuer-Event oder bei keinem Eingang wiederherzustellen, wird eine Batterie in Reihe mit dem Widerstand R geschaltet.

Technisch lässt sich dieses Verhalten als ein elektrisches Ersatzschaltbild wie in Abbildung 3.1 darstellen [21].

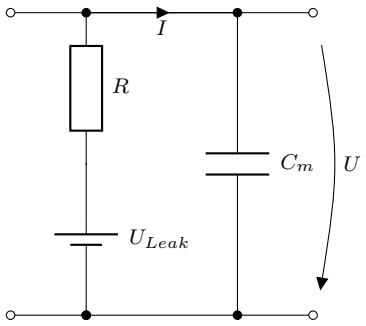

Abb. 3.1: Ersatzschaltbild der Zellmembran

Um nun eine geeignete Differenzialgleichung herzuleiten, wird zuerst das erste Kirchhoffsche Gesetz angewendet

$$I = I_R + I_C. \tag{3.1}$$

Der Strom I_R ist einfach durch das Ohmsche Gesetz wie folgt zu berechnen

$$I_R = \frac{U_R}{R} = \frac{U - U_{Leak}}{R}. \tag{3.2}$$

Der Strom I_C wird durch die Definition eines Kondensators $C_m = \frac{q}{U}$ zum kapazitiven Strom

$$I_C = \frac{dq}{dt} = C_m \frac{dU}{dt}. \tag{3.3}$$

Hierbei steht q für die elektrische Ladung und U für die anliegende Spannung.

Einsetzen von (3.2) und (3.3) in (3.1) ergibt

$$I = \frac{U - U_{Leak}}{R} + C_m \frac{dU}{dt}. \tag{3.4}$$

Wird diese Gleichung mit R multipliziert und umgestellt, bildet sich die folgende lineare Differenzialgleichung erster Ordnung:

$$RC_m \frac{dU}{dt} = (U_{Leak} - U) + RI. \tag{3.5}$$

Der Strom I wird als Eingangsgröße verstanden und im weiteren Verlauf als I_{in} betitelt. Nach Division durch RC und Einführung des Leitwerts $G_{Leak} = \frac{1}{R}$ entsteht die gewollte Form:

$$\frac{dU}{dt} = \frac{G_{Leak}(U_{Leak} - U) + I_{in}}{C_m}. \tag{3.6}$$

In dieser Gleichung stehen die Variablen G_{Leak}, U_{Leak} und C_m für Parameter der betrachteten Nervenzelle, während I_{in} stellvertretend für alle eingehenden Ströme aus Stimuli, chemischen Synapsen und Gap-Junctions steht

$$I_{in} = \sum_{i=1}^{n} I_{Stimuli} + \sum_{i=1}^{n} I_{Syn} + \sum_{i=1}^{n} I_{Gap}. \tag{3.7}$$

Die Implementierung dieser Gleichungen und den entsprechenden numerischen Lösungsverfahren findet sich in Abschnitt 3.2. Ein beispielhafter Spannungsverlauf bei einem konstanten, positiv einfließendem Strom I_{in} wird in Abbildung 3.2 dargestellt.

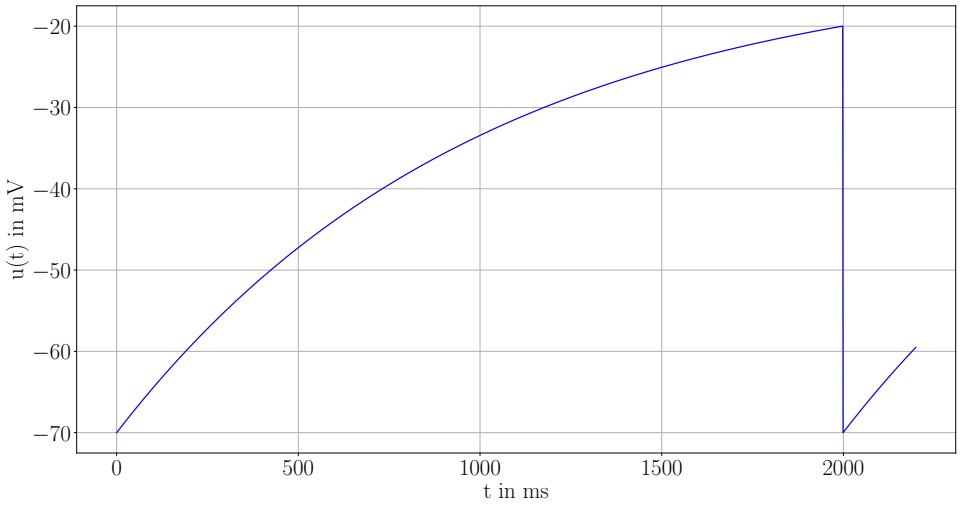

Abb. 3.2: Grafische Darstellung des Membranpotentials durch das *LIF* - Modell.

Die anliegenden Synapsenströme sind durch folgenden formularen Zusammenhang zu berechnen [9]:

$$I_{Syn} = \frac{w}{1 + \mathrm{e}^{\sigma(u_{pre}+\mu)}}(E - u_{post}). \tag{3.8}$$

Synapsenströme sind grundsätzlich von den pre- und postsynaptischen Potentialen der jeweiligen Nervenzellen u_{pre} und u_{post} abhängig. Weiterhin können diese chemischen Synapsen exzitatorisch oder inhibitorisch wirken. Diese Eigenschaft wird durch das sog. Nernstpotential $E \in [-90\ \mathrm{mV}, 0\ \mathrm{mV}]$ beschrieben. Weitere Größen dieser Gleichung bilden die Kreisfrequenz w, die Standardabweichung σ und der Erwartungswert μ.

Gap-Junctions bilden die Ausnahme, denn sie dienen als Ausgleichsglied und wirken bidirektional. Ihr Strom wird wie folgt berechnet:

$$I_{Gap} = \hat{w}(u_{post} - u_{pre}). \tag{3.9}$$

Für die Berechnung des Gap-Junction Stroms benötigt es ebenfalls das pre- und postsynaptische Potenzial der jeweiligen Nervenzellen u_{pre} und u_{post}, sowie die Kreisfrequenz $\hat{w}$.

3.2 Anwendung auf Modelle neuronaler Netze

Durch das im vorherigen Kapitel beschriebene *LIF* - Modell ist es möglich, interne Vorgänge eines neuronalen Netzes zu beschreiben und zu simulieren. Dies setzt jedoch einen konstanten Eingang der vier Sensorneuronen durch äußere Stimuli voraus. Diese Rezeptoren sind in der Lage, äußere Einflüsse wie bspw. Licht- oder Berührungsintensität in eine für das neuronale Netz verständliche Größe zu übersetzen. Wie bereits eingangs erwähnt, existiert ein Aktionsraum $A \in [-70\text{ mV}, -20\text{ mV}]$, wobei -70 mV als Ruhespannung und -20 mV als Aktionspotential wahrgenommen wird. Aufgabe der vier Sensor-Neuronen PVD, PLM, AVM und ALM ist es folglich, eingehende Größen entsprechend auf den gegebenen Aktionsraum A zu übersetzen.

In dem bereits thematisierten Schaubild nach Lechner et al (Abbildung 2.3) werden jeweils zwei Sensorneuronen für einen Eingang genutzt, da zwischen positiven und negativen Eingangsgrößen unterschieden wird. PLM und AVM bilden das primäre Sensorpaar für die ausschlaggebendste Eingangsgröße (inverses Pendel: Winkel φ), PVD und ALM bedienen eine sekundäre Eingangsgröße (inverses Pendel: Winkelgeschwindigkeit $\dot{\varphi}$ oder Wagenposition x). Diese Wahl beruht auf der internen Verschaltung des Netzwerks durch Synapsen und Gap-Junctions.

Um nun die jeweiligen Größen durch die Sensorneuronen zu übersetzen, werden folgende Funktionen für die jeweils positive und negative Sensorneurone $S_{positiv}$ und $S_{negativ}$ angenommen:

$$S_{positiv} := \begin{cases} -70\text{ mV} & x \leq 0 \\ -70\text{ mV} + \frac{50\text{ mV}}{x_{min}} x & 0 < x \leq x_{min} \\ -20\text{ mV} & x > x_{max} \end{cases} \tag{3.10}$$

$$S_{negativ} := \begin{cases} -70\text{ mV} & x \geq 0 \\ -70\text{ mV} + \frac{50\text{ mV}}{x_{min}} x & 0 > x \geq x_{min} \\ -20\text{ mV} & x < x_{max} \end{cases} \tag{3.11}$$

$x \in [x_{min}, x_{max}]$ ist eine messbare, dynamische Systemvariable, welche in den gegebenen Grenzen x_{min} und x_{max} auftritt. Lediglich eine Fallunterscheidung wird getroffen: nimmt x einen positiven Wert an, wird Sensorneurone $S_{positiv}$ aktiviert, bei negativem x-Wert, agiert die Sensorneurone $S_{negativ}$.

Analog lässt sich dieser Zusammenhang auf die beiden Motorneuronen REV und FWD übertragen. Hier werden die Signale der internen Nervenzellen AVA und AVB auf interpretierbare Größen in die Außenwelt übersetzt. Biologisch kann dies ein Nervenimpuls sein, welcher eine spezielle Muskelgruppe anspricht oder einen Reflex auslöst. In der oben genannten Simulationsumgebung des inversen Pendels entspricht der Ausgang des Netzwerks entweder einer diskreten Vorwärts- oder einer Rückwärtsbewegung. So reagiert der Wagend es Pendels auf die Feuer-Signale der Motor-Neuronen AVA und AVB. Genaueres zu der Interaktion mit dem genannten Simulationskonstrukt wird im Kapitel 5 beschrieben.

3.3 Zuverlässigkeit und Limitationen

Das *LIF* - Modell ist stark vereinfacht und zeigt die grundsätzlichen Eigenschaften des Membranpotentials auf. Es erfolgt eine Integration der anliegenden Ströme und eine simple Rücksetzung des Aktionspotentials nach Überschreitung des Schwellenwertes ϑ auf das Ruhepotential U_{Leak}.

Zur weiteren Analyse eines neuronalen Netzwerks besonders im Bereich der Biologie und Biochemie werden daher detailliertere Modelle angewendet, um biologische Effekte in verschiedenen Zelltypen zu berücksichtigen. Jedoch eignet sich das hier angewendete Modell sehr gut zur Analyse der gegebenen Nervenzellen. Das *LIF* - Modell ist in der Lage, sog. Feuer-Events bei der Überschreitung des genannten Schwellenwertes exakt zu ermitteln und liefert somit eine grundlegende Zeitbasis für die Simulationsumgebung.

Da das biologische neuronale Netzwerk qualitativ betrachtet werden soll und eine spätere Optimierung durch Parameterfindung und Gewichtung erfolgt, wird das *LIF* - Modell weiterhin verwendet.

3.4 Implementierung

Zur Implementierung des *LIF* - Modells wird die Programmiersprache `Python` verwendet. Angelehnt an die Formeln aus Abschnitt 3.1 kann ein einfacher Algorithmus implementiert werden. Der gesamte Code befindet sich im zugehörigen GitHub-Repository[1].

Da sich in der Berechnung der Membranpotentiale eine lineare Differenzialgleichung erster Ordnung ergibt (siehe (3.6)), muss diese entsprechend numerisch gelöst werden. Die Lösung kann durch das Euler-Verfahren, das Verfahren nach Heun sowie durch die Methode nach Runge-Kutta gefunden werden, wobei letztere (4. Ordnung) deutlich genauer ist. Folgende numerische Lösungsverfahren wurden dem Buch „Nonlinear Dynamics and Chaos“ [17] entnommen:

Numerisches Lösungsverfahren nach Euler

Gegeben sei eine Differenzialgleichung der Form $\dot{x} = f(x)$ mit der Bedingung $x = x_0$ bei $t = t_0$. Man finde einen Weg, um die Lösung $x(t)$ zu approximieren.
Weiterhin sollte die Schrittweite Δt bekannt sein sowie die Anzahl der Zeitschritte T. Somit lässt sich die Differenzialgleichung numerisch lösen:

$$x_{n+1} = x_n + f(x_n)\Delta t \tag{3.12}$$

[1] https://github.com/J0nasW/BA

Numerisches Lösungsverfahren nach Heun

Gegeben sei ebenfalls eine Differenzialgleichung der Form $\dot{x} = f(x)$ mit der Bedingung $x = x_0$ bei $t = t_0$. Man finde einen Weg, um die Lösung $x(t)$ zu approximieren.
Weiterhin sollte die Schrittweite Δt bekannt sein sowie die Anzahl der Zeitschritte T. Somit lässt sich die Differenzialgleichung numerisch lösen:

$$\tilde{x}_{n+1} = x_n + f(x_n)\Delta t \tag{3.13}$$

$$x_{n+1} = x_n + \tfrac{1}{2}[f(x_n) + f(\tilde{x}_{n+1})]\Delta t \tag{3.14}$$

Dieses Verfahren ermöglicht eine genauere Approximation als die einfache Euler-Methode bei gleichbleibender Schrittweite. Der Fehler $E = |x(t_n) - x_n|$ wird kleiner.

Numerisches Lösungsverfahren nach Runge-Kutta 4. Ordnung

Gegeben sei eine Differenzialgleichung der Form $\dot{x} = f(x)$ mit der Bedingung $x = x_0$ bei $t = t_0$. Man finde einen Weg, um die Lösung $x(t)$ zu approximieren.
Weiterhin sollte die Schrittweite Δt bekannt sein sowie die Anzahl der Zeitschritte T. Somit lässt sich die Differenzialgleichung numerisch lösen:

$$\begin{aligned} k_1 &= f(x_n)\Delta t \\ k_2 &= f(x_n + \tfrac{1}{2}k_1)\Delta t \\ k_3 &= f(x_n + \tfrac{1}{2}k_2)\Delta t \\ k_4 &= f(x_n + k_3)\Delta t \end{aligned} \tag{3.15}$$

$$x_{n+1} = x_n + \tfrac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4) \tag{3.16}$$

Dieses Verfahren ermöglicht eine genauere Approximation als die Euler- und Heun-Methode bei gleichbleibender Schrittweite Δt. Der Fehler $E = |x(t_n) - x_n|$ wird signifikant kleiner. Diese Methode erfordert jedoch eine höhere Rechenzeit und ist daher nur bei ausreichender Leistung anzuwenden. Anwendung des Lösungsverfahrens nach Runge-Kutta (Gleichung (3.15)) auf die Funktion (3.6) resultiert in folgende Berechnung, welche direkt implementiert werden kann:

$$\begin{aligned} k_1 &= \frac{G_{leak}(U_{leak} - u(t)) + (I_{Stimuli} + I_{Syn} + I_{Gap})}{C_m}\Delta t \\ k_2 &= \frac{G_{leak}(U_{leak} - (u(t) + \tfrac{1}{2}k_1)) + (I_{Stimuli} + I_{Syn} + I_{Gap})}{C_m}\Delta t \\ k_3 &= \frac{G_{leak}(U_{leak} - (u(t) + \tfrac{1}{2}k_2)) + (I_{Stimuli} + I_{Syn} + I_{Gap})}{C_m}\Delta t \\ k_4 &= \frac{G_{leak}(U_{leak} - (u(t) + k_3)) + (I_{Stimuli} + I_{Syn} + I_{Gap})}{C_m}\Delta t \end{aligned} \tag{3.17}$$

Rekursive Berechnung der vier Koeffizienten führt zum neuen Membranpotential und entsprechend zu der Information, ob die internen Nervenzellen *AVA* oder *AVB* gefeuert haben:

$$u_{t+1}(t) = u(t) + \tfrac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4). \tag{3.18}$$

Um diese Funktion im Gesamtcode später aufrufen zu können, wird ein Python-Script (`modules/lif.py`) erstellt. Dieses enthält neben der Funktion zur Berechnung des Membranpotentials auch die der Berechnung von Synapsen- und Gap-Junction-Strömen.

Im weiteren Verlauf werden Algorithmen zur Suche der entsprechenden Parameter des biologischen neuronalen Netzes eingeführt. In diesen wird eine Funktion `compute` implementiert, welche das Modul `lif.py` aufruft. Um eine effiziente Berechnung der Membranpotentiale und Synapsen- bzw. Gap-Junction Ströme zu gewährleisten, wird die Funktion wie folgt aufgebaut:

Algorithmus 1: compute

Input : $\boldsymbol{x}, \boldsymbol{u}, A, B, \boldsymbol{C_m}, \boldsymbol{G_{Leak}}, \boldsymbol{U_{Leak}}, \boldsymbol{\sigma}, \boldsymbol{w}, \hat{\boldsymbol{w}}$
Output: $\boldsymbol{x}, \boldsymbol{u}, \boldsymbol{fire}, \boldsymbol{I_{Syn}}, \boldsymbol{I_{Gap}}$

for $i \leftarrow 0$ ***to*** 4 **do**
  for $j \leftarrow 0$ ***to*** 4 **do**
    if $A_{i,j} == 1$ **then**
      I_inter$_{i,j}$ = I_syn_calc($\boldsymbol{x}[i], \boldsymbol{x}[j], E_{in}, \boldsymbol{w}[k], \boldsymbol{\sigma}[k], \mu$)
      k ← k + 1
    else if $A_{i,j} == 2$ **then**
      I_inter$_{i,j}$ = I_syn_calc($\boldsymbol{x}[i], \boldsymbol{x}[j], E_{ex}, \boldsymbol{w}[k], \boldsymbol{\sigma}[k], \mu$)
      k ← k + 1
    else
      I_inter$_{i,j}$ = 0
    end
    if $B_{i,j} == 1$ **then**
      I_sensor$_{i,j}$ = I_syn_calc($\boldsymbol{u}[i], \boldsymbol{u}[j], E_{in}, \boldsymbol{w}[k], \boldsymbol{\sigma}[k], \mu$)
      l ← l + 1
    else if $B_{i,j} == 3$ **then**
      I_sensor$_{i,j}$ = I_gap_calc($\boldsymbol{u}[i], \boldsymbol{x}[j], \hat{\boldsymbol{w}}[k]$)
      m ← m + 1
    else
      I_sensor$_{i,j}$ = 0
    end
  end
end
for $i \leftarrow 0$ ***to*** 4 **do**
  I_inter = I_inter.sum(axis = 0)
  I_sensor = I_sensor.sum(axis = 0)
  x[i], fire[i] = U_neuron_calc($x[i], I\_inter[i], I\_sensor[i], \boldsymbol{C_m}[i], \boldsymbol{G_{Leak}}[i], \boldsymbol{U_{Leak}}[i], v, \Delta t$)
end
return $\boldsymbol{x}, \boldsymbol{u}, \boldsymbol{fire}, \boldsymbol{I_{Syn}}, \boldsymbol{I_{Gap}}$

Die Vektoren $\boldsymbol{x}$ und $\boldsymbol{u}$ spiegeln die aktuellen Membranpotentiale der jeweiligen Nervenzellen wider:

$$\boldsymbol{x} = \begin{bmatrix} u_{AVA} & u_{AVD} & u_{PVC} & u_{AVB} \end{bmatrix}^T \text{ und} \tag{3.19}$$

$$\boldsymbol{u} = \begin{bmatrix} u_{PVD} & u_{PLM} & u_{AVM} & u_{ALM} \end{bmatrix}^T. \tag{3.20}$$

Vektor $\boldsymbol{x}$ beschreibt das Membranpotential interner Nervenzellen, Feuer-Events der Neuronen AVA und AVB sind später von Interesse. Das Potential der Eingangsneuronen $\boldsymbol{u}$ wird durch die Berechnungsvorschriften (3.10) und (3.11) je nach Sensordaten gesetzt.

Matrizen A und B werden als Transitionsmatrizen genutzt, um die Verbindungen der Nervenzellen im neuronalen Netz zu beschreiben.

$$A = \begin{array}{c} \\ AVA \\ AVD \\ PVC \\ AVB \end{array} \begin{array}{c} \begin{array}{cccc} \Rsh & AVA & AVD & PVC \quad AVB \end{array} \\ \begin{pmatrix} 0 & 0 & 1 & 1 \\ 2 & 0 & 2 & 0 \\ 0 & 2 & 0 & 2 \\ 1 & 1 & 0 & 0 \end{pmatrix} \end{array} \tag{3.21}$$

beschreibt Verbindungen innerhalb der internen Nervenzellen. Dabei stehen die Ziffern $0, 1, 2$ für folgende Verbindungen:

0 : Keine Verbindung zwischen Neuronen A_i und A_j

1 : Inhibitorische Verbindung zwischen Neuronen A_i und A_j

2 : Exzitatorische Verbindung zwischen Neuronen A_i und A_j.

Die Matrix

$$B = \begin{array}{c} \\ PVD \\ PLM \\ AVM \\ ALM \end{array} \begin{array}{c} \begin{array}{cccc} \Rsh & AVA & AVD & PVC \quad AVB \end{array} \\ \begin{pmatrix} 0 & 1 & 1 & 0 \\ 1 & 1 & 3 & 0 \\ 0 & 3 & 1 & 1 \\ 0 & 1 & 1 & 0 \end{pmatrix} \end{array} \tag{3.22}$$

beschreibt analog die Verbindungen der Sensor-Neuronen mit den internen Nervenzellen. Verbindungen werden zwischen diesen Typen von Nervenzellen nur durch inhibitorische Synapsen und Gap-Junctions hergestellt. Die Ziffern $0, 1, 3$ haben folgende Bedeutung:

0 : Keine Verbindung zwischen Neuronen B_i und B_j

1 : Inhibitorische Verbindung zwischen Neuronen B_i und B_j

3 : Verbindung durch Gap-Junction zwischen Neuronen B_i und B_j.

Durch diese Vorschriften ist eine Implementierung des gegebenen neuronalen Netzes möglich und die Berechnung essenzieller Größen durch einfache Matrixoperationen zu realisieren.
Ein entsprechendes Modell des neuronalen Netzes lässt sich durch den Zusammenhang

$$\dot{x} = A\boldsymbol{x} + B\boldsymbol{u} \tag{3.23}$$

beschreiben. Für die spätere Implementierung sind die gezeigten Gleichungen und Systembeschreibungen essenziell und werden im weiteren Verlauf wieder aufgegriffen.

Kapitel 4
Reinforcement Learning - Lernen mit Belohnung

Reinforcement Learning (kurz: RL) kann als einer der drei großen Bereiche des *Machine Learning* interpretiert werden. Neben den Bereichen *Supervised-* und *Unsupervised Learning* deckt es ein weites Spektrum an Anwendungsfeldern ab.

Die grundsätzliche Vorgehensweise im *Reinforcement Learning* ist simpel: Ein Agent ist in der Lage eine Simulation oder ein Spiel zu bedienen. Seine Aktion beeinflusst eine gut bekannte Umwelt bzw. Simulationsumgebung. Die Ergebnisse dieser Aktion werden durch das Beobachten der Umwelt bzw. der Simulation interpretiert und eingeschätzt. Der Lernprozess erfolgt, indem der Agent durch die Interpretierung der Observation und einer Belohnung eine Aktion tätigt, welche diese maximieren soll. Durch die immer größer werdende Datenbasis fällt es dem Agenten mit fortgeschrittener Simulation immer leichter, die „richtigen“ Aktionen zu treffen, um die maximale Belohnung zu erhalten.

4.1 Reinforcement Learning - eine Abwandlung des Deep Learning

Deep Learning hat in den letzten Jahren immer mehr an Relevanz gewonnen. Obwohl der Grundstein dieser Algorithmen und Vorgehensweisen bereits Ende des 19. Jahrhunderts gelegt wurde, fehlte es damals sowohl an Rechenleistung, als auch an hoch parallelen Rechenstrukturen. In der Theorie ist das Konstrukt des Deep Learning in der Lage, bei gegebenen Berechnungsmodellen mit multiplen verbundenen Ebenen, Strukturen in großen Datenmengen zu erkennen. Durch heute verfügbare Rechenleistungen können Strukturen ein beliebig hohes Abstraktionslevel aufweisen. Anwendungsbereiche für Deep Learning bewegen sich meist im Bereich der Bild- oder Spracherkennung und Klassifizierung, breiten sich jedoch auch auf weitere Bereiche wie Medizin (Pharmazie, Genom-Entschlüsselung) oder Wirtschaft (Kunden-Kaufverhalten, Logistik) aus. Dabei zeichnet einen guten Deep Learning Algorithmus die Fähigkeit aus, sog. Raw-Files (unbearbeitete Signale wie bspw. Audio-Dateien oder Bilder) ohne Vorwissen auf die gewünschten Daten zu untersuchen und zu klassifizieren, ohne aufwendige Filter, Feature-Vektoren oder andere Mittel zur Vorklassifikation zu nutzen.

Supervised Learning (zu Deutsch: überwachtes Lernen) bildet die Grundlage und wurde in den Anfängen der künstlichen Intelligenz eingesetzt. Ein Algorithmus lernt aus gegebenen Paaren von Ein- und Ausgängen eine Funktion, welche nach mehrmaligen Trainingsläufen Assoziationen herstellen soll und auf neue Eingaben passende Ausgaben liefert [11].

Unsupervised Learning (zu Deutsch: unüberwachtes Lernen) bietet entgegen der Methode des supervised Learning die Möglichkeit, ein Modell ohne im Voraus bekannte Zielwerte oder Belohnungssysteme durch die Umwelt zu trainieren. Entsprechend benötigen diese Algorithmen mehr Rechenleistung (bei gleichbleibender Aufgabenstellung). Sie versuchen, in einer Anhäufung von Datenstrukturen zu erkennen, welche von stochastischem Rauschen abweichen. Neuronale Netze orientieren sich hier oft an den bekannten Eingängen. Diese Methode wird oft in Bereichen der automatischen Klassifizierung oder Dateikomprimierung genutzt, da hier das Ergebnis im Vorhinein meist unbekannt ist [11].

Reinforcement Learning bietet, wie bereits in der Einleitung erwähnt, den Vorteil eines Belohnungssystems.

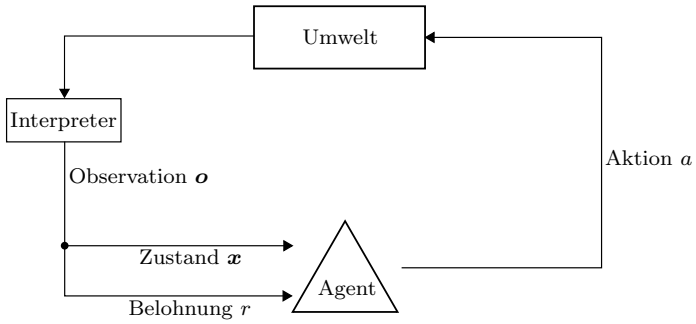

Abb. 4.1: Graphische Darstellung des *Reinforcement Learning* Algorithmus.

Der Agent beginnt mit einer anfangs willkürlich gewählten Aktion und beeinflusst damit die Umwelt bzw. die Simulation. Durch einen Interpreter ist es möglich, wichtige Messgrößen (inverses Pendel: Winkel φ oder Winkelgeschwindigkeit $\dot{\varphi}$) zu messen und in einen Observationsvektor $\boldsymbol{o}$ zu schreiben. Dieser kann ausgelesen werden und den aktuellen Zustand $\boldsymbol{x}$ nach der erfolgten Aktion liefern. Dazu wird durch ein anfangs definiertes Lohn-System eine vereinbarte Belohnung r geliefert, welche die Performance der Simulation widerspiegelt. Der Agent besitzt nun diese Informationen und entscheidet aufgrund des gegebenen Zustandes sowie der Belohnung, welche Aktion als nächstes getätigt werden soll. In der Theorie wird so die Belohnung mit jeder erfolgreichen Episode höher und der Agent ist in der Lage, gewisse Parameter der Simulation entsprechend des jeweiligen Observationsparameters anzupassen.

Bei dieser Methode ist die Grundlage aller Algorithmen und Optimierungsverfahren die Gesamtbelohnung

$$G_t = \sum_{k=0}^{T} r_{t+k+1}. \tag{4.1}$$

Des Weiteren ist es geläufig, einen sog. „Discount-Faktor“ γ einzuführen. Belohnungen in frühen Schritten der Simulation sind wahrscheinlicher und gut vorherzusehen, wohingegen in fortgeschrittenen Simulationen die Aktionen meist schwer vorhersehbar sind und somit eine höhere Belohnung verdienen.

$$G_{t\gamma} = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \text{ mit } \gamma \in [0, 1) \tag{4.2}$$

Von der Benutzung eines solchen Discount-Faktors wird jedoch vorerst abgesehen, da das Finden der perfekten Parameter für die vorgestellte Simulation im Vordergrund steht. In weiteren Anwendungen kann dieser Faktor eingeführt werden.

4.2 Anwendung auf Modelle neuronaler Netze

Reinforcement Learning findet klassischerweise Anwendung durch Deep Learning Algorithmen auf künstlich erstellten neuronalen Netzen mit vielen s.g. *Hidden Layers* (Ebenen zwischen Ein- und Ausgang mit hoher Anzahl an Neuronen) statt. Variiert werden in einem solchen Netz lediglich die jeweiligen Gewichte der Synapsen zwischen den Neuronen. Synapsen sind darüber hinaus einfache Mittel zur Informationsübertragung und haben keine weiteren Eigenschaften oder zeigen kein eigenes Verhalten.

Das hier vorliegende neuronale Netzwerk ist jedoch gänzlich anders aufgebaut. Nervenzellen werden durch Potenziale beschrieben und integrieren anliegende Informationen auf. Synapsen können verschiedener Art sein und entsprechend hemmend sowie erregend wirken. Sowohl Nervenzellen als auch Synapsen und Gap-Junctions haben verschiedene Parameter, welche gewisse Aktionen im neuronalen Netz verursachen können.

Daher wird die Methode des *Reinforcement Learning* auf biologische neuronale Netze abgewandelt, um diese auf Probleme der Regelungstechnik anzuwenden. Folglich befassen wir uns mit einem neuronalen Netz, welches eine Ebene mit vier Neuronen aufweist. Diese arbeiten wie bereits in Kapitel 2 und 3 beschrieben ebenfalls anders als in den üblichen Modellen künstlicher neuronaler Netze.

Die Schwierigkeit dieser Aufgabenstellung besteht darin, geeignete Parameter für jede Nervenzelle sowie für jede Synapse und Gap-Junction zu finden, sodass das Netz korrekt und zuverlässig auf interpretierte Signale aus der Umwelt reagiert und entsprechend durch den Agenten eine Aktion wählt, welche eine möglichst hohe Belohnung nach sich zieht. Bezogen auf Abbildung 4.1 stellt die Umwelt unsere Simulationsumgebung des inversen Pendels (OpenAI Gym - `CartPolev0`) dar. Diese nimmt eine Aktion (FWD oder REV) pro Simulationsschritt an und gibt entsprechend einen Observationsvektor $\mathbf{o}$ aus, welcher durch den Interpreter übersetzt wird. Der aktuelle Zustand x wird durch die vier Sensorneuronen PVD, PLM, AVM und ALM entsprechend interpretiert und in das neuronale Netz eingegeben.

4.3 Verschiedene Suchalgorithmen

Die Wahl des geeigneten Suchalgorithmus ist immer von der Beschaffenheit der Problemstellung abhängig. Klassische Probleme mit Anwendung des *Reinforcement Learning* auf künstliche neuronale Netze nutzen Algorithmen wie Q-Learning, *Policies* (Epsilon-Greedy, Gradient-Decend und -Acend) oder genetische Algorithmen. Diese sind hoch spezialisiert und suchen nach Maxi-

ma der gegebenen Funktion, um den Fehler zu reduzieren. Bei einer großen Zahl an Parametern, welche untereinander noch korreliert sein können, kommt oft der einfache, jedoch gleichzeitig sehr effektive „Random-Search“ Algorithmus zum Einsatz.

Grundsätzlich sei noch zu erwähnen, dass konventionelle Such- bzw. Optimierungsalgorithmen innerhalb des *Reinforcement Learning* ein Markov-Entscheidungsproblem voraussetzen.

Anmerkung 4.1 (Markov Eigenschaft und Umgebung). Als Markov Eigenschaft[1] bezeichnet man, wie stark ein stochastischer Prozess von der eigenen Vergangenheit abhängt. Diese Bedingung erlaubt es, Markov-Prozesse zu beschreiben.

Durch eine Markov Umgebung ist es möglich, aus einer begrenzten Anzahl an vergangenen Zuständen die Wahrscheinlichkeit für das Eintreten zukünftiger Ereignisse durch selbst gewählte Aktionen vorherzusagen. [16]

4.3.1 Random-Search

Gewisse Probleme in der Domäne des *Reinforcement Learning* erfordern einen verallgemeinerten Ansatz zum Finden von optimalen Parametern. Das hier vorliegende Problem bietet durch eine große Anzahl an Parametern eine Vielzahl an lokalen Maxima in der Belohnungsfunktion und bereitet daher den meisten zielgerichteten Algorithmen Probleme bei der Anwendung. Ein Anpassen an die geforderten Umstände ist im Grunde möglich, erfordert jedoch einen hohen Rechenaufwand und führt unter Umständen zu keiner Verbesserung der Ergebnisse. Daher wird die Methode des Random-Search angewendet.

Wie bereits kurz in Kapitel 1 erwähnt, werden Parameter für die Simulation in vorher festgelegten Grenzen durch eine Gleichverteilung erzeugt. Diese werden auf eine Simulation angewendet und die Performance wird anhand der Belohnung ausgewertet. Durch ein simples High Score System werden Parameter mit guter Belohnung gespeichert, schlechte Simulationen werden verworfen. Durch den Einsatz von genügend Rechenleistung und langen Simulationszeiten können Parameter mit guten Simulationseigenschaften gefunden werden (siehe Anhang C).

4.3.2 Genetische Algorithmen

Die Anwendung genetischer Algorithmen im Bereich des *Reinforcement Learning* ist ebenfalls schon seit einiger Zeit bekannt und führt in den richtigen Situationen zu zufriedenstellenden Ergebnissen.

Der Grundstein dieser Optimierungsverfahren wurde von Holland et al. in seinem Werk „Adaption in Natural and Artificial Systems“ [7] gelegt. Basierend auf den bereits von Darwin [3] beobachteten Phänomenen der Natur, setzen genetische Algorithmen bei dem Ansatz „Survival of the Fittest“ an. Grundsätzlich kann die Vorgehensweise genetischer Algorithmen wie folgt dargestellt werden [4]:

[1] Nach Andrei Markov (1856 - 1922)

- Die erste Generation an Parametern wird zufällig initialisiert. Gleich der Random-Search Methode werden über eine Gleichverteilung verschiedene Parameter erzeugt.
- Es werden Simulationen mit den Parametern der ersten Generation gefahren. Die entsprechende Güte wird anhand des Rewards festgelegt.
- Durch eine festgelegte Grenze werden Kandidaten der ersten Generation mit sehr guten Parametern selektiert, welche zur Rekombination genutzt werden
- Die Rekombination kann als eine Aktualisierung der Parametergrenzen verstanden werden.
- Durch Mutation werden anhand der neuen Parametergrenzen erneut zufällige Parameter erzeugt. Diese werden wieder durch Simulation evaluiert und sollten in der Theorie nun bessere Ergebnisse erzielen.
- Noch einmal erfolgt eine Selektion basierend auf neuen Auswahlkriterien der Mutationen.

Die Schritte der Selektion, Rekombination, Mutation und Evaluierung werden bis zu einem gewählten Abbruchkriterium durchlaufen.

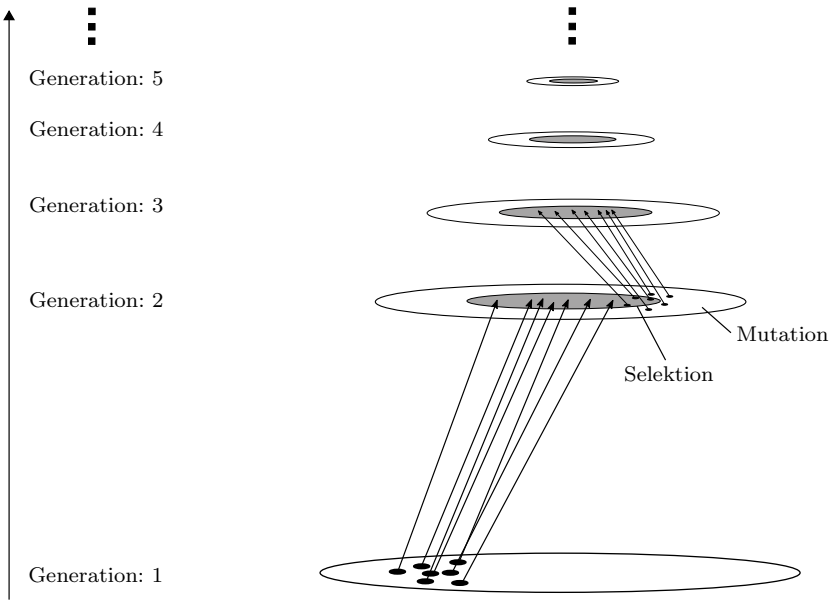

Abb. 4.2: Graphische Darstellung des genetischen Algorithmus.

Wie in Abbildung 4.2 anschaulich dargestellt, verringert sich mit jeder Generation der Parameterraum und die Simulation konvergiert optimaler Weise zu einem globalen Maximum. Dieses hängt jedoch stark von der Anzahl der Selektionen sowie der gewählten Varianz bei Mutation ab. Hier ist ein optimaler Trade-Off zwischen Rechenleistung und Simulationsdauer zu finden.

Wie in Kapitel 5 beschrieben, findet die Anwendung genetischer Algorithmen auf das vorgestellte biologische Netzwerk statt.

4.3.3 Q-Learning

Die Methode des Q-Learnings wurde zuerst von Watkins [19] definiert und vorgestellt. Voraussetzung um diese Algorithmen anzuwenden, ist eine kontrollierte Markov Umgebung. Ziel der Q-Learning Methode ist es, die Qualität der getätigten Aktionen bei unterschiedlichen Simulationsbedingungen zu verbessern. Dabei wird ein Agent eingesetzt, welcher lernt, in einer Markov Umgebung optimal zu handeln, indem die Konsequenzen der Aktionen sofort zurückgeführt, analysiert und verarbeitet werden. Dem Agenten ist zu jedem Zeitpunkt der Simulation die Umwelt unbekannt.

Unmittelbar nach einer getätigten Aktion a erhält der Agent neben dem Zustand x (ausgewählte Messgrößen wie bspw. der Winkel des inversen Pendels φ) die Belohnung $R_x(\pi(x))$. Aus diesen Informationen lässt sich der Wert V^π des erhaltenen Zustandes x berechnen:

$$V^\pi(x) \equiv R_x(\pi(x)) + \gamma \sum_y P_{xy}[\pi(x)] V^\pi(y) \tag{4.3}$$

mit γ als Diskontierungsfaktor der nächsten Belohnung und P_{xy} als Wahrscheinlichkeit der nächsten vorhergesagten Veränderung der Umwelt.

Nach Watkins existiert mindestens eine optimale stationäre Vorgehensweise („Policy“) π^* für welche gilt

$$V^*(x) \equiv V^{\pi^*}(x) = \max_a \left\{ R_x(a) + \gamma \sum_y P_{xy}[a] V^{\pi^*}(y) \right\}. \tag{4.4}$$

Ziel des sog. „Q-Learner“ ist es, diese optimale Vorgehensweise zu finden. So lassen sich die charakteristischen Q-Values

$$Q^\pi(x, a) = R_x(a) + \gamma \sum_y R_{xy}[\pi(x)] V^\pi(y) \tag{4.5}$$

berechnen. Diese spiegeln die erwartete, diskontierte Belohnung bei Ausführung einer Aktion a mit Zustand x und der darauf folgenden Vorgehensweise π wieder. Zusammenfassend kann durch die Methode des Q-Learning eine optimale Vorgehensweise des Agenten erzielt werden, wenn die entsprechenden Q-Values der optimalen Vorgehensweise gefunden bzw. erlernt werden.

4.3.4 Gradient Policies

Eine weitere Möglichkeit, Probleme durch *Reinforcement Learning* zu lösen, ist die Anwendung sog. *Gradient Policies*. Dies stellt ein klassisches Optimierungsproblem dar und fordert in erster Linie ebenfalls eine Markov Umgebung.

Es wird eine gegebene Vorgehensweise $\pi_\theta(x, a)$ mit Parametern θ angenommen. Ziel ist es, die optimalen Parameter θ zu finden, um die Belohnung zu maximieren. Um die Qualität der Vorgehensweise π_θ zu messen, wird

$$J(\theta) = V^{\pi_\theta}(x) \tag{4.6}$$

als Qualitätsgröße abhängig von der gegebenen Vorgehensweise sowie dem Zustand x eingeführt. Policy Gradient Algorithmen suchen nach einem lokalen Maximum in $J(\theta)$, indem sie sich entlang des Gradienten der Vorgehensweise

$$\Delta\theta = \alpha \nabla_\theta J(\theta) \tag{4.7}$$

bewegen. α ist dabei ein Schrittweitenparameter. Somit ist $\nabla_\theta J(\theta)$ definiert als

$$\nabla_\theta J(\theta) = \begin{pmatrix} \frac{\partial J(\theta)}{\partial \theta_1} \\ \vdots \\ \frac{\partial J(\theta)}{\partial \theta_n} \end{pmatrix}. \tag{4.8}$$

Bei Anwendung von Gradient Policies stellt sich eine gute Konvergenzeigenschaft des Lernalgorithmus ein. Durch das stetige Bewegen auf dem erlernten Gradienten der Qualitätsgröße $J(\theta)$ wird ein Maximum gefunden. Jedoch spiegelt dieses lediglich ein lokales Maximum wider und ist mit geringer Wahrscheinlichkeit gleichzeitig ein globales Optimum. Durch die Korrelation zahlreicher verschiedener Parameter im gegebenen neuronalen Netz bilden sich viele lokale Maxima aus. Darüber hinaus bietet sich die Methode bei großen Aktionsräumen und langen Laufzeiten an, da selbst stochastische Prozesse erlernt werden können. [16]

Wie im vorherigen Abschnitt 4.2 bereits kurz beschrieben, werden die jeweiligen Parameter der Synapsen und Nervenzellen gesucht. Dies sind die folgenden:

Parameter-Typ	*Parameter*	*Beschreibung*	*Grenzen*
Membranpotential	C_m	Kapazität der Zellmembran	$[1\text{ mF}, 1\text{ F}]$
Membranpotential	G_{Leak}	Leitwert der Zellmembran	$[50\text{ mS}, 5\text{ S}]$
Membranpotential	U_{Leak}	Ruhepotential der Zellmembran	$[-90\text{ mV}, 0\text{ mV}]$
Synapsenstrom	$E_{Excitatory}$	pos. Beeinflussung des Membranpotentials	0 mV
Synapsenstrom	$E_{Inhibitory}$	neg. Beeinflussung des Membranpotentials	$[-90\text{ mV}]$
Synapsenstrom	μ	Erwartungswert (Modelle)	$[-40\text{ mV}]$
Synapsenstrom	σ	Standardabweichung (Modell)	$[0.05, 0.5]$
Synapsenstrom	w	Kreisfrequenz der Synapsen	$[0\text{ S}, 3\text{ S}]$
Synapsenstrom	$\hat{w}$	Kreisfrequenz der Gap-Junctions	$[0\text{ S}, 3\text{ S}]$

Tabelle 4.1: Grenzen der essentiellen Parameter im biologischen neuronalen Netz.

Die gegebenen Grenzen folgen aus [9] und [6] und sind durch Calcium und Potassiummengen im Nervensystem des *C. Elegans* errechnet worden.

Kapitel 5
Implementierung des neuronalen Netzes

Die Implementierung des gesamten neuronalen Netzes, inklusive der Simulationsumgebung, erfolgt in der Programmiersprache `Python`. Als Module werden zum einen das bereits vorgestellte *LIF* - Modell implementiert, zum anderen diverse Algorithmen zur Suche von individuellen Parametern des neuronalen Netzes. Darüber hinaus ist das Programm in der Lage, eine Simulation der gefundenen Parameter durch die Simulationsumgebung `CartPole_v0` von OpenAI Gym [1] zu zeigen und Parameter über die Simulationszeit darzustellen. Die Module, sowie diverse Dokumentationen und Informationen, sind im GitHub-Repository[1] zu finden. Ein entsprechendes Datenblatt mit weiteren Informationen liegt dieser Arbeit in Anhang B bei.

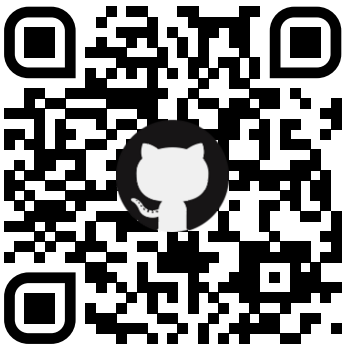

Abb. 5.1: QR-Code Verweis zum GitHub-Repository.

5.1 Aufbau des Programms

Ein Ziel dieser Arbeit ist es, neben der Funktionstüchtigkeit des Simulators, das entstandene Programm, mitsamt allen Modulen und Abhängigkeiten, modular und leicht verständlich aufzubauen. Dazu gehört eine gute Dokumentation sowie eine saubere Versionierung, um Änderungen nachvollziehbar darzustellen. Folgende Anforderungen werden an das Programm gestellt:

- Es existiert ein zentraler Punkt zum Ändern aller nötigen Parameter. Alle weiteren Größen werden durch Formeln und Abfragen erzeugt.

  Datei: `parameters.py`

- Es wird ein Modul zur Visualisierung gegebener Parameter oder Gewichte des neuronalen Netzes bereitgestellt. Diese Datei muss leicht verständlich und manipulierbar sein, um eigene Schaubilder (siehe Abbildungen 5.9 und 5.10) zu erstellen und neue Simulationsumgebungen einzubinden.

[1] https://github.com/J0nasW/BA

Datei: `visiualize.py`

- Es muss die Möglichkeit bestehen, aus bereits existierenden Suchalgorithmen neue Implementationen zu erstellen, um gegebene Funktionen einfach einsetzen zu können.

  Dateien: `random_search_v2.py`, `weights_nn.py`, `genetic_algorithm.py`

Aufgrund der hohen Vielfältigkeit an neuronalen Netzen und Suchalgorithmen soll dieses Programm als Basis für neue Projekte und Ideen dienen. Daher wird empfohlen, eine Fork des Repositories (siehe Anhang B) zu erstellen und den Simulator weiter zu gestalten.
Das Programm beinhaltet folgende Module:

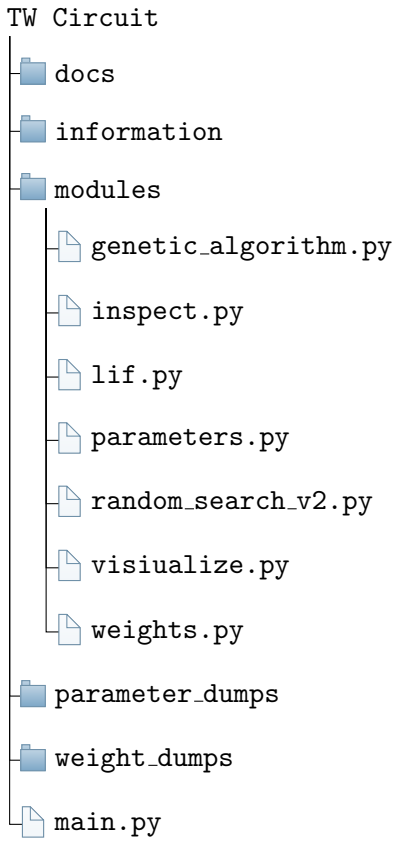

- Der Ordner `docs` beinhaltet wichtige Dokumentationen bezüglich des Codes und dem Umgang mit diversen Befehlen innerhalb der `main.py`. Darüber hinaus wird hier ebenfalls diese Arbeit inklusive des LaTeX-Codes abgelegt.
- Aufgrund vieler komplexer Simulationen mit verschiedenen Parametersätzen wurde die Berechnung von Heim- und Unirechnern auf Rechenzentren ausgelagert. Der Ordner `information` wird genutzt, um Informationen über jede Simulation (Ergebnisse, Zeitstempel, Zugehörigkeit, ...) in Form einer TXT-Datei zu speichern.
- Alle nötigen Module zur Simulation und Visualisierung finden sich in dem Ordner `modules` wieder. Genauere Informationen zu den einzelnen Skripten werden in den nächsten Abschnitten aufgeführt.
- Parameter-Dumps und Weight-Dumps sind die Resultate der Simulationsläufe. In diesen Ordnern werden Parameter und Gewichte des neuronalen Netzes nach erfolgreichen Simulationsläufen abgespeichert. Die Dateien werden durch das Paket `Hickle` in ein HDF-5 Dateiformat [5] gespeichert.

5.2 Implementierung der Suchalgorithmen

Die Suchalgorithmen befinden sich in dem Ordner `modules` und werden durch Import in der Datei `main.py` aufgerufen. Sie erhalten bei Aufruf die vom Anwender gewählte Simulationszeit (bspw. 12 Stunden) und bei Bedarf bereits errechnete Parameter. Als Ausgabe wird ein Dump der errechneten Parameter oder Gewichte gespeichert sowie eine Informationsdatei, welche Zugehörigkeiten, Anzahl an Simulationen, Laufzeiten und die gesamte Belohnung beschreibt.

5.2.1 Suchalgorithmus Random-Search

Der Suchalgorithmus Random-Search wurde direkt in die Simulation eingebunden. Es werden die Parameter $C_m, G_{Leak}, U_{Leak}, \sigma, w$ und $\hat{w}$ durch eine Gleichverteilung in den bereits genannten Grenzen zufällig erzeugt. Um gleichverteilte, zufällige Werte zu generieren, wird die Funktion `random.uniform` aus dem bekannten Package `numpy` [13] verwendet.

Algorithmus 2: random_parameters

```
   Input  : Anz. Nervenzellen, Anz. Synapsen, Anz. Gap-Junctions
   Output: Arrays C_m, G_Leak, U_Leak, σ, w, ŵ
   // Generieren von Zufallsvariablen durch Gleichverteilung.
   // Für Nervenzellen:
1  C_m = np.random.uniform(low = 0.01, high = 1, size = (1,Anz. Nervenzellen))
2  G_leak = np.random.uniform(low = 0.05, high = 5, size = (1,Anz. Nervenzellen))
3  U_leak = np.random.uniform(low = -70, high = 0, size = (1,Anz. Nervenzellen))
   // Für Synapsen:
4  σ = np.random.uniform(low = 0.05, high = 0.5, size = (1,Anz. Synapsen))
5  w = np.random.uniform(low = 0, high = 3, size = (1,Anz. Synapsen))
6  ŵ = np.random.uniform(low = 0, high = 03, size = (1,Anz. Gap-Junctions))
7  return C_m, G_Leak, U_Leak, σ, w, ŵ
```

Nach Aufruf des Algorithmus `random_parameters` wird eine Simulation mit den erzeugten Parametern und maximal 200 Zeitschritten durchgeführt. Die Belohnung dieser Simulation wird mit vergangenen Belohnungen verglichen. Wenn die Simulation eine Belohnung größer oder gleich 200 erreicht, gilt sie als erfolgreich, andernfalls wird nach Ablauf der Simulationszeit der Algorithmus unterbrochen.
Der gesamte Programmablauf gestaltet sich vereinfacht wie folgt:

Algorithmus 3: random_search_v2

```
   Input  : Simulationszeit
   Output: Simulationsinformation (information.txt), Parameter-Dump als .hkl Datei
1  action = episodes = best_reward = 0
2  env = gym.make('CartPole-v0')
3  while True do
4  |  initialize(Default_U_leak)
5  |  episodes ← episodes + 1
6  |  C_m, G_Leak, U_Leak, σ, w, ŵ = random_parameters()
7  |  reward = run_episode(C_m, G_Leak, U_Leak, σ, w, ŵ) ;   // Simulation mit neuen Parametern - Siehe
   |    Abschnitt 5.4
8  |  if reward ≥ best_reward then
9  |  |  Set best_reward ← reward
10 |  |  Result = [C_m, G_Leak, U_Leak, σ, w, ŵ] ;   // Für Parameter-Dump
11 |  |  if reward ≥ 200 then
12 |  |  |  break;   // Exit-Argument, wenn Belohnung von 200 erreicht wurde
13 |  |  end
14 |  end
15 |  if elapsed_time > simulation_time then
16 |  |  break ;   // Exit-Argument, um genaue Laufzeiten zu erzielen
17 |  end
18 end
19 return information.txt, parameter_dump.hkl, date, best_reward
```

Die elementare Funktion `run_episode` wird in Abschnitt 5.4 genauer erläutert. Sie enthält unter anderem auch die Funktion `compute`, welche in Abschnitt 3.4 bereits detailliert thematisiert worden ist.

5.2.2 Suchalgorithmus Genetic Algorithm

Als Alternative zu dem Algorithmus `Random-Search` wird ein weiterer Suchalgorithmus `Genetic Algorithm` implementiert. Anhand der Beschreibung aus Abschnitt 4.3.2 wird anfangs analog zu Random-Search ein Parametersatz aus einer Gleichverteilung mit festen Grenzen erzeugt. Dieser Parametersatz wird für die Simulation einer gegebenen Anzahl an Episoden genutzt, der sog. ersten Generation. Diese wird nachfolgend untersucht und ausgewertet. Aus der ersten Generation wird eine gewisse Anzahl an sehr guten Parameterläufen (mit hoher Belohnung) isoliert, die entsprechenden Parameter werden analysiert, um auf neue Grenzen der Gleichverteilung von Zufallsparametern in der nachfolgenden Generation zu schließen. Somit bildet sich wie in Abbildung 4.2 gezeigt eine zielführende Suche nach Parametern, welche für eine stabile Simulation sorgen.

Grenzen der Gleichverteilung für zufällige Parameter werden mit zunehmender Anzahl an Generationen justiert und konvergieren auf einen optimalen Wert. Abbildungen 5.2 und 5.3 zeigen einen beispielhaften Verlauf der Konvergenz verschiedener Parameter auf.

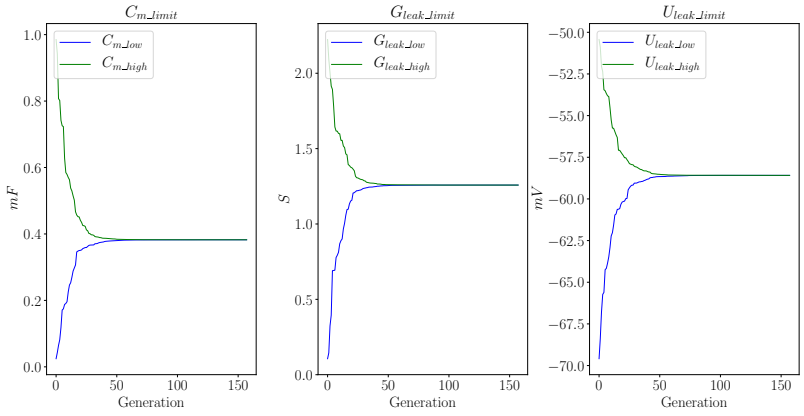

Abb. 5.2: Gleichverteilungsgrenzen von Parametern der Nervenzellen.

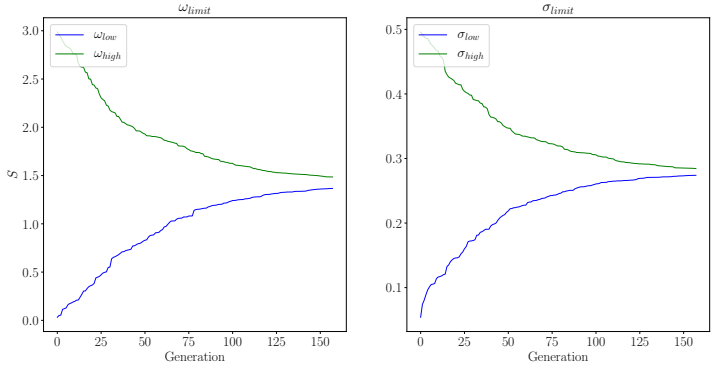

Abb. 5.3: Gleichverteilungsgrenzen von Parametern der Synapsen.

5.2.3 Optimierungsalgorithmus Weights

Als erstes Optimierungsverfahren, nach erfolgreicher Simulation der Parameter des neuronalen Netzes, wird nun der Algorithmus Weights eingesetzt. Dieser lässt die bereits simulierten Parameter importieren und gewichtet jede Synapse mit einem Faktor $g \in [0, 1]$. Durch einfache Simulationen mit willkürlichen Gewichten wird schnell festgestellt, welche Synapsen, bei einem Simulationslauf mit hoher Belohnung, eine große Gewichtung erhalten und welche Synapsen nicht förderlich für das Ergebnis sind. Durch diese Simulation ist es möglich, das in Kapitel 2 vorgestellte symmetrische neuronale Netz (Abbildung 2.4) zu entwickeln. Die dort gezeigten Synapsen erfahren eine relevante Gewichtung und sind somit wichtig für die stabile Regelung durch das neuronale Netz.

Der Gewichtungsalgorithmus ist rechenintensiver als der Algorithmus Random-Search, da insgesamt 16 Synapsen bzw. Gap-Junctions pro Episode mit zufällig gewählten Gewichten versehen werden, um die Belohnung zu steigern. Jedoch wird eine im Schnitt um das Dreifache höhere Belohnung verzeichnet (bei gleichbleibenden Parametern), was eine sehr gute Optimierung darstellt. Aufgerufen wird dieser Algorithmus analog zu Random-Search aus der `main.py`-Datei. Als Input werden die bereits errechneten optimalen Parameter der jeweiligen Nervenzellen und Synapsen sowie die maximale Simulationszeit eingegeben. Ebenfalls gleich dem Algorithmus Random-Search produziert Weights einen Dump mit den errechneten Gewichten der Synapsen und Gap-Junctions sowie eine Informationsdatei im `.txt`-Format, welche weitere Zugehörigkeitsinformationen, die Anzahl an Simulationen und die Dauer enthält.

5.3 Simulation in der Google Cloud Platform®

Wie bereits mehrfach erwähnt, sind die implementierten Suchalgorithmen Random-Search und Weights äußerst rechenintensiv. Beide Skripte erfordern das zufällige Generieren einer hohen Anzahl an Parametern sowie die Anwendung dieser Parameter auf das gegebene Problem durch numerische Lösungsansätze für Differenzialgleichungen (siehe Abschnitt 3.4). Es müssen Parameter zwischengespeichert und Dumps auf Festplatten geschrieben werden.

Um eine erfolgreiche Simulation des inversen Pendels zu erhalten, muss ein Parametersatz mit hoher Belohnung gefunden werden, welcher die korrekte Funktionsweise des neuronalen Netzes gewährleistet. Bei dem in Abbildung 2.4 gezeigten neuronalen Netz werden die Parameter $C_m, G_{Leak}, U_{Leak}, \sigma, w$ und $\hat{w}$ für Synapsen, Gap-Junctions und Nervenzellen simuliert.

Parameter	*Kategorie*	*Anzahl*
C_m	Nervenzelle	4
G_{Leak}	Nervenzelle	4
U_{Leak}	Nervenzelle	4
σ	Synapse	16
w	Synapse	16
$\hat{w}$	Synapse	2
Gesamt:		**46**

Somit werden in jedem Simulationslauf zuerst 46 Parameter in gegebenen Grenzen durch eine Gleichverteilung erzeugt und anschließend durch das `compute`-Modul (siehe Abschnitt 3.4) die benötigten Synapsenströme und Membranpotentiale errechnet.
Das Modul Weights erzeugt, analog zu Random-Search, zuerst für jede Synapse und Gap-Junction ein gleichverteiltes, zufälliges Gewicht $g \in [0, 1]$.

Parameter	*Kategorie*	*Anzahl*
g	Synapse	18
Gesamt:		**18**

Es werden insgesamt 18 Gewichte pro Episode erzeugt und auf das Modell angewendet. Zur Berechnung der erforderlichen Ströme und Potenziale wird das `compute`-Modul um die Funktion der Gewichtung erweitert.

Ein solches Simulationsvorhaben wird üblicherweise aufgrund zu geringer Ressourcen nicht mehr auf Heimrechnern ausgeführt, sondern findet den Weg in die Cloud. Gerade in den letzten Jahren haben Cloud-Computing-Firmen wie Amazon mit AWS[2], Microsoft mit der Azure Cloud[3] und Google mit der Google Cloud Platform (GCP)[4] an großer Aufmerksamkeit gewonnen. Die einfache Handhabung und Kontrolle über eigene virtuelle Instanzen von ganzen Betriebssystemen erlaubt eine zuverlässige und effiziente Simulation von Parametern. In dieser Angelegenheit fiel die Entscheidung auf die Google Cloud Plattform, da diese kostengünstige, virtuelle Maschinen anbietet. Gemietet wurde ein Server mit dem Standort Frankfurt a. M., welcher über vier virtuelle Intel XEON® Prozessoren sowie 12 GB DDR4 Arbeitsspeicher verfügt. Dies erlaubt eine schnelle Simulation von vier Instanzen zur gleichen Zeit sowie den Vorteil, dass Langzeitsimulationen von 12 Stunden oder mehr im Hintergrund oder über Nacht erfolgen können.

Auf der virtuellen Instanz wurde ein Linux Ubuntu 18.04 LTS installiert und bereitgestellt. Im nächsten Schritt wird die vorbereitete GitHub Repository auf das System geklont und die benötigten Abhängigkeiten (siehe Anhang B) installiert. Durch einen Cronjob werden Skripte ausgeführt und mit `crontab -e` die Simulation zu einer festen Uhrzeit gestartet. Die übliche Simulationszeit beträgt 12 Stunden.

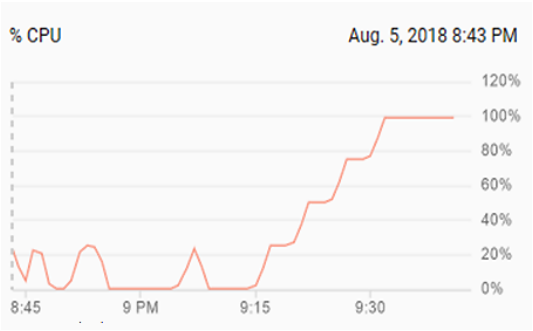

Abb. 5.4: Systemauslastung der virtuellen Instanz - GCP Dashboard

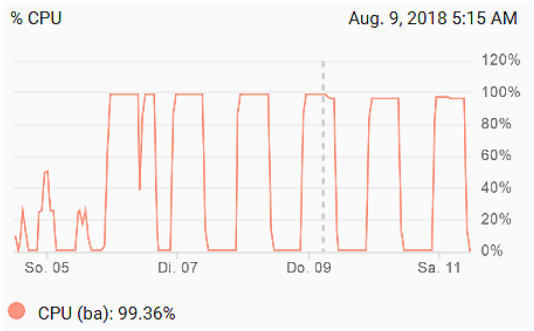

Abb. 5.5: Systemauslastung der virtuellen Instanz im Dauerbetrieb (Cronjob)

[2] https://aws.amazon.com/de/
[3] https://azure.microsoft.com/de-de/
[4] https://cloud.google.com/

Wie in Abbildung 5.4 zu sehen, werden die Suchalgorithmen parallel mit einem Versatz von wenigen Minuten durch den Cronjob ausgeführt, da pro Suchlauf nur ein Prozessorkern in Anspruch genommen werden kann. Der virtuelle Prozessor erreicht somit bei vier gleichzeitigen Simulationsläufen eine Auslastung von 100 % (siehe Abbildung 5.5).

Die Ergebnisse der Suchläufe werden in Form von Parameter- und Weight-Dumps über einen Apache Webserver bereitgestellt und können problemlos auf dem Heimrechner visualisiert werden. Durch das gewählte Dateiformat der Dumps in HDF-5 [5] sind die Dateien Plattformunabhängig und äußerst performant lesbar. Diese Methode funktioniert darüber hinaus auch versionsübergreifend. Eine Simulation kann Dumps mit Python 2.7 erstellen, welche durch einen Heimrechner mit Python 3.x visualisiert werden können.

5.4 Simulationsumgebung: OpenAI Gym

Um die Performance eigener neuronaler Netze und Algorithmen zu messen, sind in den letzten Jahren eine ganze Reihe an Simulationen und Spielen entwickelt worden. Ziel dieser Simulationsumgebungen ist es, die Entscheidung des Agenten in gewissen Situationen zu testen und den Lernerfolg darzustellen. Darüber hinaus wird das Verständnis für neuronale Netze durch das Anwenden auf Spiele und Experimente vertieft.

Eine sehr bekannte Open Source Bibliothek an Simulatoren und Spielen ist Gym von OpenAI [1]. OpenAI ist eine Non-Profit Organisation mit dem Ziel, den Forschungsbereich der künstlichen Intelligenz voran zu treiben und ein besseres Verständnis für die Vorgänge in neuronalen Netzen zu schaffen. Die Bibliothek `Gym` enthält verschiedene Umgebungen:

- Algorithmen:

  Einfache Aktionen wie Copy-Paste, Addition und Subtraktion sowie logische Gatter

- Atari

  Sammlung an klassischen Atari Spielen wie Breakout, Pacman und Space Invaders

- Classic Control

  Simulationsumgebungen wie das inverse Pendel oder das Mountain Car

- Robotics

  Komplexe Simulationen von Roboterarmen oder -händen

In dieser Arbeit wird die Umgebung `CartPole_v0` (Abb. 5.6) gewählt. Diese besteht aus einem einfachen inversen Pendel, welches sich auf einer zweidimensionalen Bahn frei bewegen kann.

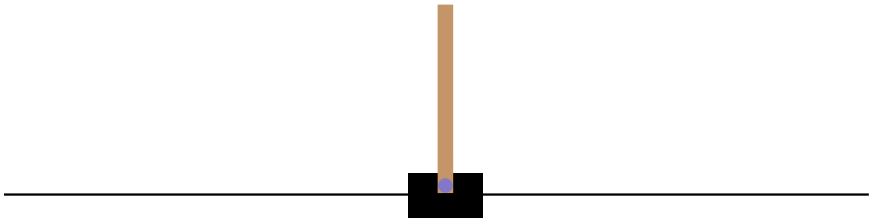

Abb. 5.6: Simulationsumgebung `CartPole_v0`.

Die Handhabung dieser Simulationsumgebung ist dank einer großen Community und guten Dokumentationen sehr einfach. Initialisiert wird die Umgebung, indem die Bibliothek `Gym` in das Python-Skript importiert und die gewählte Umgebung als „Environment“ festgelegt wird. Pro Simulationsschritt kann eine Aktion $a = \{0, 1\}$ getätigt werden.

0 : Schritt nach Links (REV)

1 : Schritt nach Rechts (FWD)

Das bereits vorgestellte neuronale Netz (Abbildung: 2.4) verfügt über zwei Motor-Neuronen, welche als Eingang der Simulation genutzt werden können. Interne Nervenzellen AVA und AVB sind durch eine direkte Synapse mit den genannten Motor-Neuronen verbunden und verursachen im Falle eines Feuer-Events die Bewegung des Wagens um einen Schritt nach links bzw. rechts. Pro Simulationsschritt erfolgt, je nach Observation, immer ein Feuer-Event, sodass das Pendel zu jeder Zeit eine berechnete Aktion erhält.

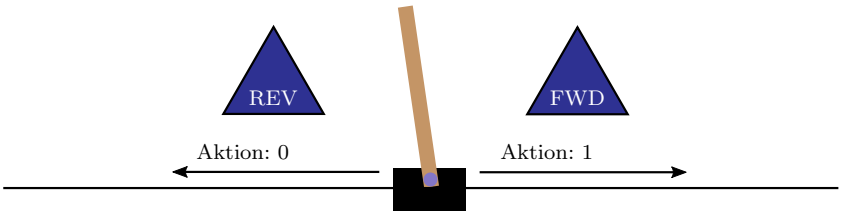

Abb. 5.7: Simulationsumgebung `CartPole_v0` mit Aktionen *FWD* und *REV*.

Pro Simulationsschritt wird ein Observationsvektor ausgegeben. Dieser enthält die folgenden Parameter:

$$\boldsymbol{o} = \left[C_{Position}\ C_{Velocity}\ P_{Angle}\ P_{Velocity}\right]^T. \tag{5.1}$$

Parameter	*Beschreibung*	*Grenzen*
$C_{Position}$	Position des Wagens	$[-2.4, 2.4]$
$C_{Velocity}$	Geschwindigkeit des Wagens	$(-\infty, \infty)$
P_{Angle}	Winkel des Pendels	$[-41, 8°, 41, 8°]$
$P_{Velocity}$	Winkelgeschwindigkeit des Pendels	$(-\infty, \infty)$

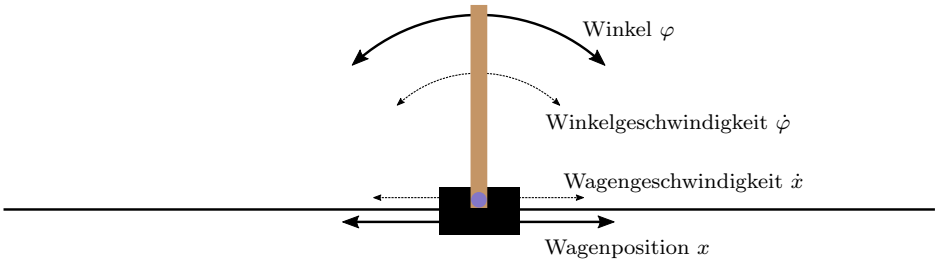

Abb. 5.8: Simulationsumgebung `CartPole_v0` mit Observationsgrößen.

Die Informationen aus dem Observationsvektor $\boldsymbol{o}$ werden entsprechend interpretiert und den Sensor-Neuronen zugeführt. Wie bereits in Abschnitt 2.3 beschrieben, ist der Winkel des Pendels φ als primäre Größe den Sensor-Neuronen PLM und AVM zuzuführen. Als sekundäre Größe kann die Winkelgeschwindigkeit $\dot{\varphi}$ oder die Position des Wagens x den Sensor-Neuronen ALM und PVD zugeführt werden. Die Wahl der geeigneten sekundären Observationsgröße ist dem neuronalen Netz zuzuschreiben. Durch die inhibitorische Beeinflussung mittels Sensor-Neuronen ALM und PVD entsteht ein dämpfendes Signal, welches dafür sorgt, dass bei zu hoher Winkelgeschwindigkeit oder Wagenposition die Kompensation durch Bewegung des Wagens nicht übersteuert.

5.5 Visualisierung und Auswertung

Wie bereits in Abschnitt 5.4 näher beschrieben, liefert die Simulationsumgebung `CartPole_v0` eine ausgezeichnete Echtzeitvisualisierung des inversen Pendels als Animation. Diese wird durch das Speichern eines errechneten RGB-Tensors jedes Simulationsschrittes und anschließenden Animieren der Informationen erreicht. Zudem soll das Programm in der Lage sein, wichtige Parameter der Simulation über die Simulationszeit darzustellen, um ggf. Probleme zu erkennen und Aktionen zu verstehen. Um grafische Darstellungen aus Arrays zu erstellen, wird die Python-Bibliothek `matplotlib` [8] genutzt. Durch die einfache Bedienung und den enormen Umfang an Werkzeugen ist diese Bibliothek für die Visualisierung von Daten und Parametern sehr bekannt.

Der generelle Ablauf des Programms sieht im ersten Schritt die Simulation von Parametern und Gewichten vor. Dies erfordert keine Visualisierung der Vorgänge, da die Performance erheblich beeinträchtigt werden würde. Aufgrund dessen ist das Modul `visiualize.py` geschrieben worden, um gefundene Parameter und Gewichte mühelos simulieren zu können. Für den Aufruf

werden die entsprechenden Parameter- und Gewichte-Dumps übergeben und die gewünschte Simulationszeit (bspw. 10 Sekunden) eingestellt. Die Simulation wird analog den Suchalgorithmen, jedoch mit festen Parametern ausgeführt. Gewünschte Größen werden pro Simulationsschritt gespeichert und letztlich grafisch dargestellt. Besonders die Übersicht über Membranpotentiale einzelner Nervenzellen bietet einen sehr guten Überblick über die Vorgänge im neuronalen Netz und die Reaktion auf gegebene Sensor-Daten.

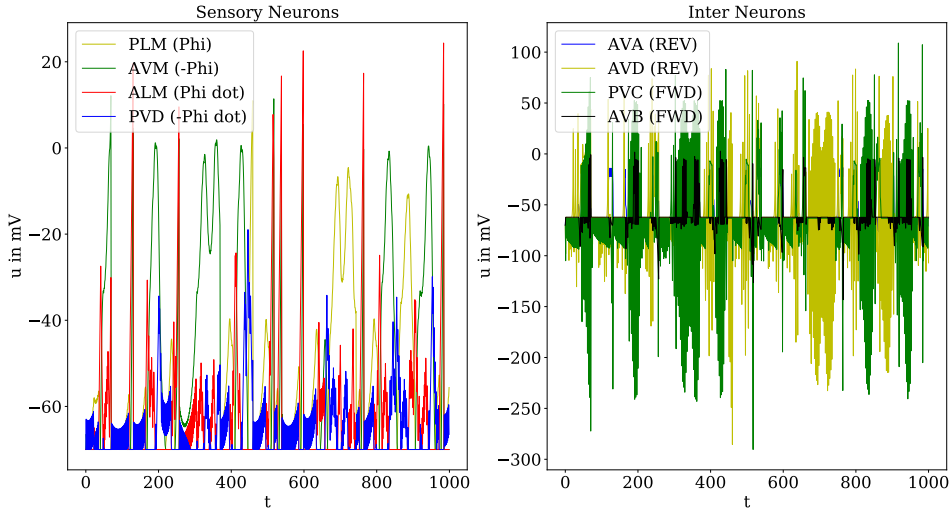

Abb. 5.9: Darstellung der Membranpotentiale von Inter- und Sensorneuronen.

Zudem wird standardmäßig neben den Membranpotentialen auch der anliegende Synapsenstrom an jeder Nervenzelle grafisch dargestellt. Diese Veranschaulichung gibt Aufschluss über die gewählten Parameter und das Feuerverhalten im internen neuronalen Netzwerk.

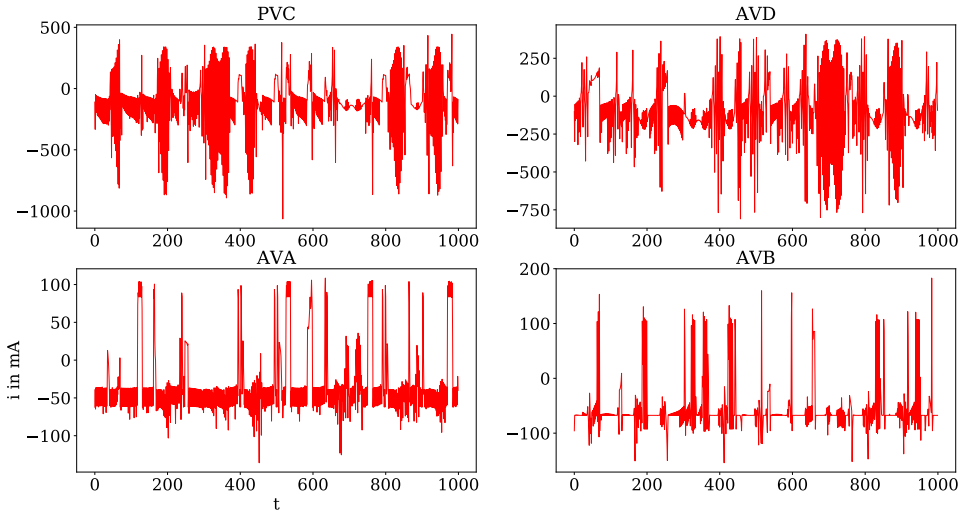

Abb. 5.10: Darstellung der anliegenden Ströme aus Stimulus, Synapsen und Gap-Junctions.

Abbildung 5.11 gibt Aufschluss über das Verhalten des Pendels bei gegebenen Eingangsgrößen:

- Winkel des inversen Pendels φ und
- Winkelgeschwindigkeit $\dot{\varphi}$.

Harte Flanken in der Abbildung stellen eine Rücksetzung der Simulationsumgebung dar. Durch verschiedene Abbruchkriterien (zu großer Winkel φ oder Wagen verlässt die Simulationsumgebung $x \leqslant 2.4$) wird sichergestellt, dass die Regelung innerhalb der Simulation dargestellt wird.

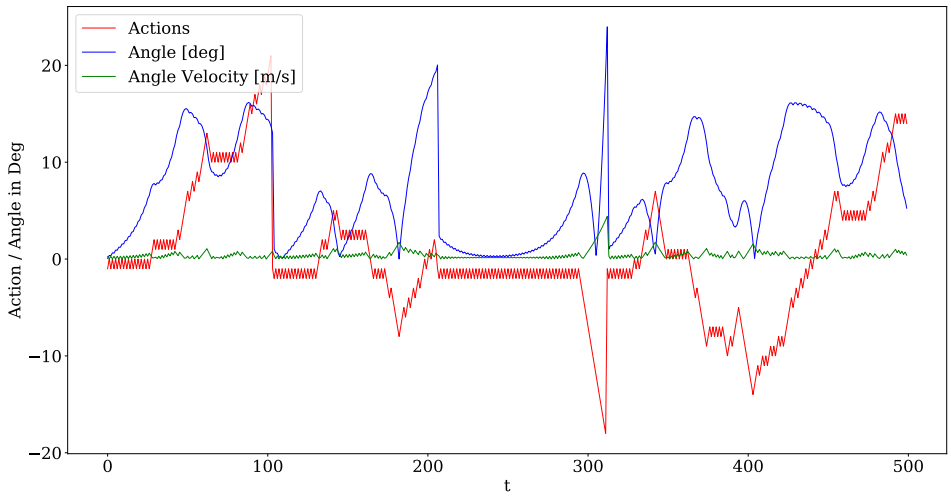

Abb. 5.11: Verhalten des Pendels bei Eingangsgrößen φ und $\dot{\varphi}$.

Als zweite Observationsgröße wurde die Winkelgeschwindigkeit $\dot{\varphi}$ gewählt, da eine Simulation mit der Eingangsgröße der Wagenposition x zu sehr trägen Reaktionen des Wagens geführt hat.

5.6 Anmerkungen zur Implementierung

Neben den prominenten Modulen wurden im Laufe der Zeit sowohl mehrere hilfreiche Nebenmodule und Funktionen implementiert, als auch notwendige Pakete genutzt.

5.6.1 Zentraler Ort für Parameter

Um einen zentralen Ort für verschiedene Größen und Parameter zu schaffen, ist das Modul `parameters.py` erstellt worden. Dieses Modul wird im gesamten Programm eingebunden und dient als globale Informationsbasis. Nur wenige Größen können verändert werden wie bspw. die Transitionsmatrizen des neuronalen Netzes (siehe (3.21) und (3.22)) oder manche Parameter

zur Berechnung von Synapsenströmen und Membranpotentialen. Alle weiteren Daten werden automatisch berechnet und im Laufe der Simulation bereitgestellt.

5.6.2 Speicherung von Daten

Nach einer erfolgreichen Simulation von Parametern soll der beste Parametersatz zur weiteren Analyse gespeichert werden. Dazu liefert Python die Bibliothek `Pickle`, welche verschiedene Datentypen seriell in ein kompaktes Binärformat konvertiert und in der `.p` Dateiendung speichert. Dieser Vorgang ist jedoch besonders mit Python 2.7 verhältnismäßig langsam und beeinträchtigt die Performance der Simulation. Darüber hinaus besteht eine Inkompatibilität des Dateiformats zum einen zwischen verschiedenen Python-Versionen, zum anderen unter unterschiedlichen Betriebssystemen.

Eine elegantere Möglichkeit bietet die Open Source Bibliothek `Hickle`. Sie wird ähnlich wie `Pickle` importiert und speichert die gewählten Parameter in einer `.hkl`-Datei. Die Daten werden anders als bei Pickle im sog. HDF-5 (Hierarchical Data Format 5) [5] gespeichert. Dies ist zum einen performanter, sorgt zum anderen für eine erheblich größere Kompatibilität unter Python-Versionen und Betriebssystemen.

5.6.3 Dateiinspektion

Um die Inspektion der errechneten Parameter und Gewichte zu ermöglichen, wird ein eigenes Modul implementiert. Hohe Belohnungen bedeuten nicht direkt, dass das neuronale Netz in jeder Situation richtig entscheidet. Beispielsweise kann eine sehr gute Belohnung in der Bewegung des Pendels in Vorwärtsrichtung erreicht werden, obwohl die Parameter der Rückwärtsbewegung nicht sehr gut gewählt sind. Daher wird ein Modul zur detaillierten Inspizierung der Dump-Dateien `inspect.py` geschrieben. Bei Aufruf einer Funktion dieses Moduls muss jeweils der Pfad der Dump-Datei übergeben werden. Die Datei wird geöffnet und die Parameter den entsprechenden Größen zugewiesen. Danach kann ein Konsolen-Output erfolgen oder eine grafische Darstellung der gespeicherten Daten erzeugt werden.

Kapitel 6
Performance & Auswertung

Dieses Kapitel dient der Auswertung von Versuchsergebnissen und dem Vergleich der verschiedenen Suchalgorithmen. Ausgangspunkt und somit Vergleichskriterium sind Simulationsgrößen des inversen Pendels `CartPole_v0` des Frameworks OpenAI `Gym`. Es wurde zuerst eine Berechnungsgrundlage eines neuronalen Netzes nach *C. Elegans* [2] geschaffen und implementiert. Dazu wurden verschiedene numerische Lösungsverfahren von Differentialgleichungen verglichen und umgesetzt [17]. Letztlich wird ein universeller Simulator geschaffen, welcher Informationen über die Nervenzellen und Synapsen erhält und entsprechend in der Lage ist, das Netz zu simulieren und Feuer-Events auszugeben. Um die Performance des neuronalen Netzes durch den Simulator zu messen, wird eine Simulationsumgebung eingebunden und ein Lern-Algorithmus implementiert. Im Folgenden wird sich auf die *Reinforcement Learning* Methode Random-Search konzentriert, die Methode der genetischen Algorithmen untersucht und auf die Optimierungsmethode durch Gewichten der entsprechenden Synapsen eingegangen.

6.1 Performance implementierter Algorithmen

Die Schnelligkeit der Ausführung von Algorithmen und ganzen Skripten ist in dieser Anwendung von großer Relevanz. Da der Simulator von Grund auf darauf ausgerichtet worden ist, später rechenintensive Simulationen von Parametern zu durchlaufen, wird bereits in der Auswahl der zusätzlich genutzten Pakete darauf geachtet, diese performant und ressourceneffizient zu implementieren.

Angefangen bei den Berechnungsmodulen in der Datei `lif.py` wird für komplexere mathematische Operationen die Erweiterung `NumPy` [13] aus dem bekannten Python-Paket `SciPy` [13] genutzt. Außerdem werden Schleifen und If-Abfragen ohne Redundanzen und unnötige Befehle implementiert, um in der höheren Abstraktionsebene einen einwandfreien Aufruf zu garantieren. Nach erfolgreichen Tests der implementierten Funktionen ist das Framework für den Simulator erstellt worden. Genutzte Pakete wie `matplotlib` [8] oder `Hickle` [5] sind ebenfalls für ihre Schnelligkeit und einfache Handhabung ausgewählt worden. Des Weiteren können hier die bereits implementierten Funktionen zur Berechnung von Synapsenströmen und Membranpotentialen einfach importiert werden.

Letztendlich ist die Ausführung der Suchalgorithmen Random-Search und Genetic Algorithm sowie die Optimierung durch den Algorithmus Weights ausschlaggebend. Diese Algorithmen

wurden im Laufe der Implementierung immer wieder optimiert und verbessert, sodass eine zuverlässige Simulation mit effizienten Laufzeiten möglich wird. Bei festen Simulationszeiten werden auf der bereits vorgestellten virtuellen Instanz folgende Ergebnisse erzielt (stichprobenartig aufgelistet):

Zeitstempel	*Belohnung*	*Laufzeit*	*Anz. Simulationen*
20180815_10-40-23	26	2 Std.	39.006
20180816_01-50-01	123	12 Std.	10.509.904
20180816_01-52-01	185	12 Std.	10.536.512
20180818_02-48-01	**200**	12 Std.	10.852.326

Tabelle 6.1: Parametersuche durch Algorithmus `Random-Search`.

Zeitstempel	*Belohnung*	*Laufzeit*	*Anz. Simulationen*
20180815_11-21-46	56	1 Std.	5.927
20180816_13-50-01	149	12 Std.	3.715.008
20180816_13-52-01	**200**	12 Std.	3.686.723

Tabelle 6.2: Optimierung durch Algorithmus `Weights`.

Diese Simulationen wurden ausnahmslos auf derselben virtuellen Instanz (parallel) ausgeführt. Die genauen Spezifikationen wurden in Abschnitt 5.2 bereits detailliert beschrieben. Auffällig ist die unterschiedliche Anzahl an Simulationen bei gleichbleibender Zeit zwischen dem Suchalgorithmus Random-Search und dem Optimierungsalgorithmus Weights. Im Schnitt werden bei der Parametersuche ca. 11 Mio. Simulationen in einem Zeitraum von 12 Stunden erfasst. Die nachgelagerte Optimierung durch den Algorithmus Weights ist jedoch rechenintensiver und erfasst innerhalb 12 Stunden lediglich ca. 3,7 Mio. Simulationen.

Der Suchalgorithmus Genetic Algorithm ist nicht auf lange Simulationszeiten ausgelegt. Durch die zielgerichtete Suche über mehrere Generationen hinweg werden die Grenzen der Gleichverteilung von Parametern aktualisiert und pendeln sich innerhalb weniger Minuten ein (siehe Abbildungen 5.2 und 5.3). Doch wie bereits in Abschnitt 4.3.2 angedeutet, wird in jedem Simulationslauf lediglich ein lokales Maximum gefunden. Dieses ist nur mit geringer Wahrscheinlichkeit auch das globale Optimum der Simulationsumgebung.

Zeitstempel	*Belohnung*	*Laufzeit*	*Anz. Simulationen*
20180905_10-12-08	11	10 Min	253.416
20180905_10-22-08	**200**	10 Min	276.505
20180905_11-22-08	31	10 Min	295.116

Tabelle 6.3: Parametersuche durch Algorithmus `Genetic_Algorithm`.

Wie der Tabelle 6.3 zu entnehmen ist, ergeben Simulationen gleicher Dauer stark divergente Belohnungs-Ergebnisse.

Letztendlich zeigen diese Daten, dass die implementierten Algorithmen in der Lage sind, dauerhafte Simulationen mit guten Ergebnissen zu erzielen. Durch kleinere Verbesserungen und Veränderungen am Code erzielte der Parametersuchlauf mit dem Zeitstempel `20180817_01-56-01` das erste Mal eine Belohnung von 200. Dieses Ergebnis beweist die Funktionsweise des Simulators und hält das Pendel in 200 von 200 Simulationsschritten erfolgreich aufrecht. Eine Animation dieser Parameter wird in Appendix C genauer erläutert und veranschaulicht.

6.2 Limitationen und Alternativen von Algorithmen

Die bereits vorgestellten Algorithmen `Random-Search` als Such- und `Weights` als Optimierungsalgorithmus führen zwar mit viel Rechenleistung und hohen Simulationszeiten zu guten und verlässlichen Ergebnissen, sind jedoch im Grunde ineffizient. Einzig die Herangehensweise durch genetische Algorithmen ist nicht sehr rechenintensiv, liefert jedoch durch die zielgerichtete Suche meist ein lokales Maximum der Belohnungsfunktion, welches meist eine geringe Belohnung aufweist.

6.2.1 Analyse bereits bestehender Algorithmen

`Random-Search` generiert Vektoren mit zufälligen Parametern innerhalb einer gegebenen Gleichverteilung und wendet diese auf die Simulationsumgebung an. Die Belohnung am Ende einer jeden Simulation sagt etwas über die Güte dieser generierten Parameter aus. Ist die Belohnung hoch, so werden die Parameter gespeichert, fällt die Belohnung geringer als die bisher beste Belohnung aus, wird diese Simulation verworfen. So baut sich ein High-Score-System auf und nach Ablauf der Simulationszeit werden die Parameter mit der höchsten erreichten Belohnung gespeichert. Wie darüber hinaus in Abbildung A.1 noch einmal verdeutlicht, werden gute Parameter für stabile Simulationsläufe durch den simplen Input der Belohnung gefunden.

Analog zu `Random-Search` beginnt der Algorithmus `Genetic Algorithm` mit zufälligen Parametern in gegebenen Grenzen. Nach einer festen Anzahl an Episoden ist eine Generation vollendet und wird untersucht. Maxima und Minimal der Parameter werden isoliert und als neue Grenzen der Gleichverteilung für zufällige Parameter gesetzt. Ein High-Score-System ermittelt wieder die besten Simulationen und entsprechende Parameter werden gespeichert (siehe Abbildung A.2).

Nach Anwendung der Parametersuche durch `Random-Search` oder `Genetic Algorithm` wird eine Optimierung des neuronalen Netzes durch den Optimierungsalgorithmus `Weights` durchgeführt. Durch das Einführen von Gewichten für Synapsen und Gap-Junctions, können gewisse Informationsbahnen eingestellt und die Simulation weiter verbessert werden. In Abbildung A.3 wird der gesamte Programmablauf noch einmal verdeutlicht. Gefundene Parameter und Gewichte guter Simulationsläufe werden in Anhang C aufgeführt.

Aufgrund der starken Symmetrie des gegebenen Problems und des neuronalen Netzes ist es darüber hinaus möglich, eine symmetrische Parameter- und Gewichtsgenerierung zu imple-

mentieren. Anstatt der gesamten 46 Parameter für Nervenzellen Synapsen und Gap-Junctions, werden jeweils nur die Hälfte der benötigten Parameter generiert und anschließend dupliziert. Dies sorgt für eine symmetrische Verteilung von zufällig generierten Parametern und einer noch effizienteren Simulation.

6.2.2 Alternative Such- und Optimierungsalgorithmen

Wie bereits in Abschnitt 4.3 vorgestellt, existieren bereits viele gute Algorithmen zur Parametersuche und -optimierung von künstlich erzeugten oder gegebenen neuronalen Netzen. Doch die Implementierung dieser Algorithmen, besonders auf die hohe Anzahl an zu variierenden Parametern, stellt eine erweiterte Anforderung dar.

Der in Abschnitt 4.3.3 zuerst vorgestellte Algorithmus des Q-Learning ist speziell für die neuen Praktiken der künstlich erschaffenen neuronalen Netze entwickelt worden. Hier wird auf die Gewichtung vieler einfacher Verbindungen zwischen Neuronen unterschiedlicher Ebenen fokussiert. Die Grundlagen könnten auf einfache Parameteroptimierungen angewendet werden, jedoch ist dieser Aspekt größtenteils unerforscht.

Die Methode, durch *Gradient Policies* eine Parameteroptimierung durchzuführen, ist durchaus möglich und kann zu effizienteren Simulationslaufzeiten führen. Problematisch ist aber die Tatsache, dass sich durch die Anzahl an zu simulierenden Parametern viele lokale Maxima in der Belohnungs-Funktion bilden und somit der Algorithmus schnell zu einem Ende kommt. Die grundsätzliche Vorgehensweise beginnt analog zu Random-Search mit einer zufälligen Generierung von Parametern und einem ersten Simulationslauf. Nach der ersten Episode wird ein weiterer, zufälliger Parametersatz generiert und eine zweite Simulation initiiert. Ist die Belohnung dieser zweiten Episode höher, werden die Parameter entsprechend verglichen und die Grenzen zur Generierung neuer, zufälliger Parameter für die nächsten Episoden aktualisiert.

Die dritte Herangehensweise der genetischen Algorithmen stellt sich als robustere Methode im Vergleich zu *Gradient Policies* heraus. Durch die Wahl mehrerer Simulationsläufe mit guten Belohnungen und die Expansion dieser Selektion (als Mutation) durch Varianzen wird ebenfalls zielgerichteter gesucht und die Chance, ein globales Optimum zu finden, erhöht. Da die Implementierung dieser Methode jedoch um ein vielfaches komplexer ist und weitere Parameter liefert, welche es zu optimieren gilt, fallen im aktuellen Stadium die Belohnungen meist gering aus. Nur wenige Ausnahmen liefern Belohnungen bis hin zu 200/200.

Einzig die Optimierung durch Gewichtung von Synapsen und Gap-Junctions kann mit bekannten Algorithmen und dem Input des Rewards das Ergebnis effizient und verlässlich beeinflussen.

Kapitel 7
Zusammenfassung & Ausblick

Dieses Kapitel schließt mit einer Zusammenfassung und einem Ausblick die Arbeit ab. Durch den modularen Aufbau des Programms und der Erarbeitung grundlegender Themen fällt der Ausblick sehr ausführlich aus.

7.1 Zusammenfassung

In Zeiten neuer Denkweisen und unkonventioneller Herangehensweisen an bestehende Probleme findet die Anwendung neuronaler Netze und künstlicher Intelligenzen immer mehr Anklang in fast allen Bereichen des Alltags und der Wissenschaft. Neue Theorien und Lernalgorithmen lassen hoch parallele Rechenkonstrukte lernen und nutzen diese Methoden, um komplexe Aufgabenstellungen zu lösen. Diese Arbeit untersucht zum einen die Grundzüge des *Deep Learning* mit Schwerpunkt auf *Reinforcement Learning*, wendet diese Erkenntnisse jedoch auf unkonventionellem Wege auf bereits bestehende neuronale Netze biologischer Lebensformen an. Dieser Ansatz wurde noch nicht oft untersucht und bietet eine neue Möglichkeit, von der Evolution zu lernen und besser als bereits bestehende Systeme zu werden.

Dies erfordert sowohl ein sehr genaues und umfassendes Verständnis von biologischen und chemischen Prozessen in neuronalen Netzen sowie medizinische Grundlagen, als auch eine ausgereifte Modellierung, welche diese Prozesse effizient und mit hoher Genauigkeit simulativ nachbilden kann. Darüber hinaus benötigt es gute Lernalgorithmen, um unbekannte Parameter und Assoziationen in neuronalen Netzen zu finden und diese auszubilden.

Prozesse innerhalb neuronaler Netze wurden bereits gut erforscht und dokumentiert. Daher konnte hier auf eine große Wissensdatenbank zurückgegriffen werden, um formulare Zusammenhänge für Größen wie Synapsenströme und Membranpotentiale herzuleiten [21]. Dies ist für den Simulator von großer Bedeutung, da somit die Signalverläufe und Feuer-Events dargestellt werden können. Wie anhand der Abbildungen 5.9 und 5.10 zu sehen ist, liefert das *LIF* - Modell eine sehr genaue und zuverlässige Simulation der Nervenzellen. Voraussetzung für eine realitätsnahe Simulation sind jedoch stimmige Parameter in jeder einzelnen Nervenzelle und Synapse bzw. Gap-Junction. Diese Parameter wurden durch Suchalgorithmen und langen Simulationsläufe gefunden und zeigen letztendlich den ursprünglichen Reflex des Wurms *C. Elegans*: *Touch-Withdrawal* (zu Deutsch: Rückwärtsbewegung bei Berührung). Des weiteren wurde der

Simulator ausgebaut, um ein gegebenes Netzwerk zur Regelung dynamischer Systeme zu nutzen. Auch dies konnte mit Erfolg nachgewiesen werden, wie in Anhang C zu sehen ist.

Zusammenfassend zeigt dieses Thema durch Kombination verschiedener Bereiche der Wissenschaft eine neue Herangehensweise an bereits bestehende Probleme der Regelungstechnik auf. Durch die Aktualität der genutzten Werkzeuge und Informationsquellen entstand eine Implementierung, welche durch das Einsetzen des *Touch-Withdrawal Neuronal Circuit* [9] erfolgreich in der Lage war, dynamische Systeme in der Regelungstechnik zu stabilisieren.

Nichtsdestotrotz gibt es nach wie vor viele Baustellen und Erweiterungsmöglichkeiten. Das Regeln des inversen Pendels ist weiterhin durch kleine Unstimmigkeiten schwierig und bricht in manchen Simulationen ab. Dies ist auf die Auswahl der Parameter sowie des Designs der bisher implementierten Suchalgorithmen zurückzuführen. Auch das selbst erstellte, symmetrische neuronale Netz (nach Abbildung 2.4) kann durch Erweiterungen nochmals optimiert werden.

7.2 Ausblick

Die Anwendung des *Reinforcement Learning* oder generell des *Deep Learning* in Bereichen der Regelungstechnik ist noch sehr neu. Besonders der Ansatz, ein existierendes, biologisches neuronales Netz zur Steuerung dynamischer Systeme zu verwenden, wurde in Fachkreisen noch nicht sehr oft dokumentiert. Daher basiert diese Arbeit auf sehr viel Grundlagenforschung zu Nervensystemen des Wurms *C. Elegans* [2] sowie der Methoden des *Reinforcement Learning* [11] [15], um eine Brücke zwischen diesen Themen zu schlagen. Es wird ein ein grundlegendes Verständnis über die Prozesse biologischer neuronaler Netze und dessen Implementierung in einen Simulator dargestellt.

Schon die Berechnungsmodelle der Synapsenströme und Membranpotentiale sind vereinfacht dargestellt. Wie in dem Buch Neuronal Dynamics [21] zu lesen ist, bietet das *LIF* - Modell zwar präzise und zuverlässige Verhaltenssimulationen der Nervenzellen, hat jedoch an anderen Stellen Nachteile, wie in Abschnitt 3.3 beschrieben ist.

Weitergehend sollen Parameter und Gewichte für das neuronale Netz gefunden werden, um eine korrekte und stabile Simulation zu erhalten. Dies ist bisher nur durch die Methode Random-Search und genetischen Algorithmen geschehen. Durch lange Simulationszeiten auf effizienten Rechnern wurden Parametersätze ermittelt, welche eine zuverlässige Regelung des inversen Pendels gewährleisten. Die Anwendung des genetischen Algorithmus führt ebenfalls zu hohen Belohnungen bereits nach kurzen Simulationszeiten (5 - 10 Minuten), diese treten jedoch selten auf, da meist in ein lokales Maximum der Belohnungsfunktion konvergiert wird (siehe Abschnitt 5.2.2). Weitere Suchalgorithmen (beschrieben in Abschnitt 4.3) könnten durch große Anpassungen ebenfalls Anwendung in der Suche nach passenden Parametern finden.

Das Framework des Simulators ist bisher mit dem Projekt gewachsen. Obwohl immer stets auf den universellen und modularen Aufbau geachtet wurde, könnte der Simulator noch allgemeiner implementiert sein und eine größere Anzahl an Funktionen aufweisen. Eine Implementierung als Paket in Python mit Verfügbarkeit über PyPI[1] könnte ebenfalls realisiert werden.

[1] www.pypi.org - Python Package Index

Abschließend wurde durch diese Arbeit ein Grundstein gelegt, welcher grundsätzliche Informationen zu den Aspekten biologischer neuronaler Netze, neuronaler Dynamik, und Algorithmen des *Reinforcement Learning* bietet. Darüber hinaus kann der Simulator `TW Circuit` aufgrund des modularen Aufbaus beliebig erweitert werden. Ein Funktionsbeweis liefert die Simulation des inversen Pendels `CartPole_v0` aus dem Paket OpenAI Gym, welche mit Erfolg durch eine Belohnung von 200 bestanden wurde (siehe Parameter in Anhang C).

Anhang A
Programmablaufpläne

A.1 `Random-Search`

Die folgende Abbildung A.1 stellt den genutzten Algorithmus `Random-Search` qualitativ in einem Programmablaufplan vor.

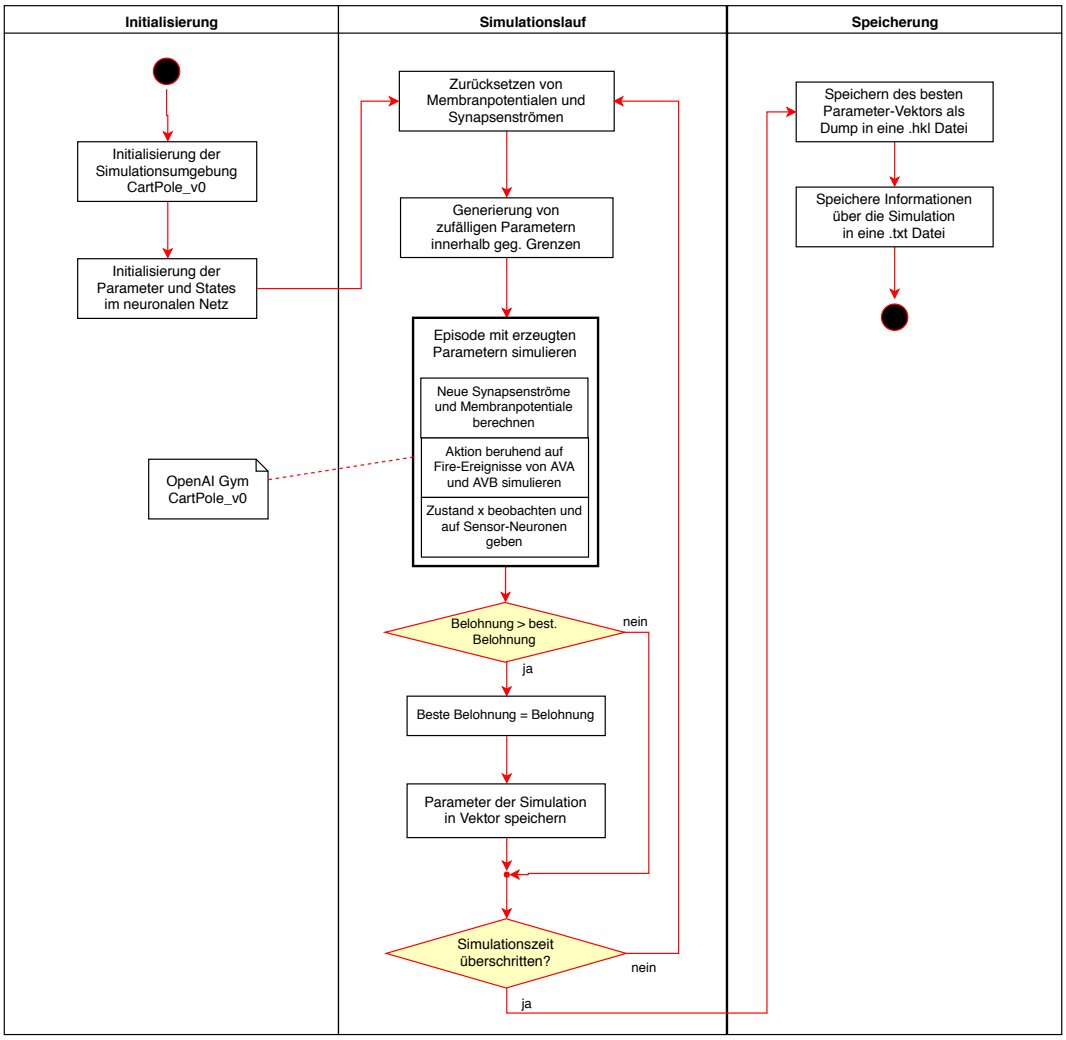

Abb. A.1: UML Diagramm des Algorithmus `Random-Search`.

A.2 Genetic Algorithm

Die folgende Abbildung A.2 stellt den genutzten Algorithmus `Genetic_Algorithm` qualitativ in einem Programmablaufplan vor.

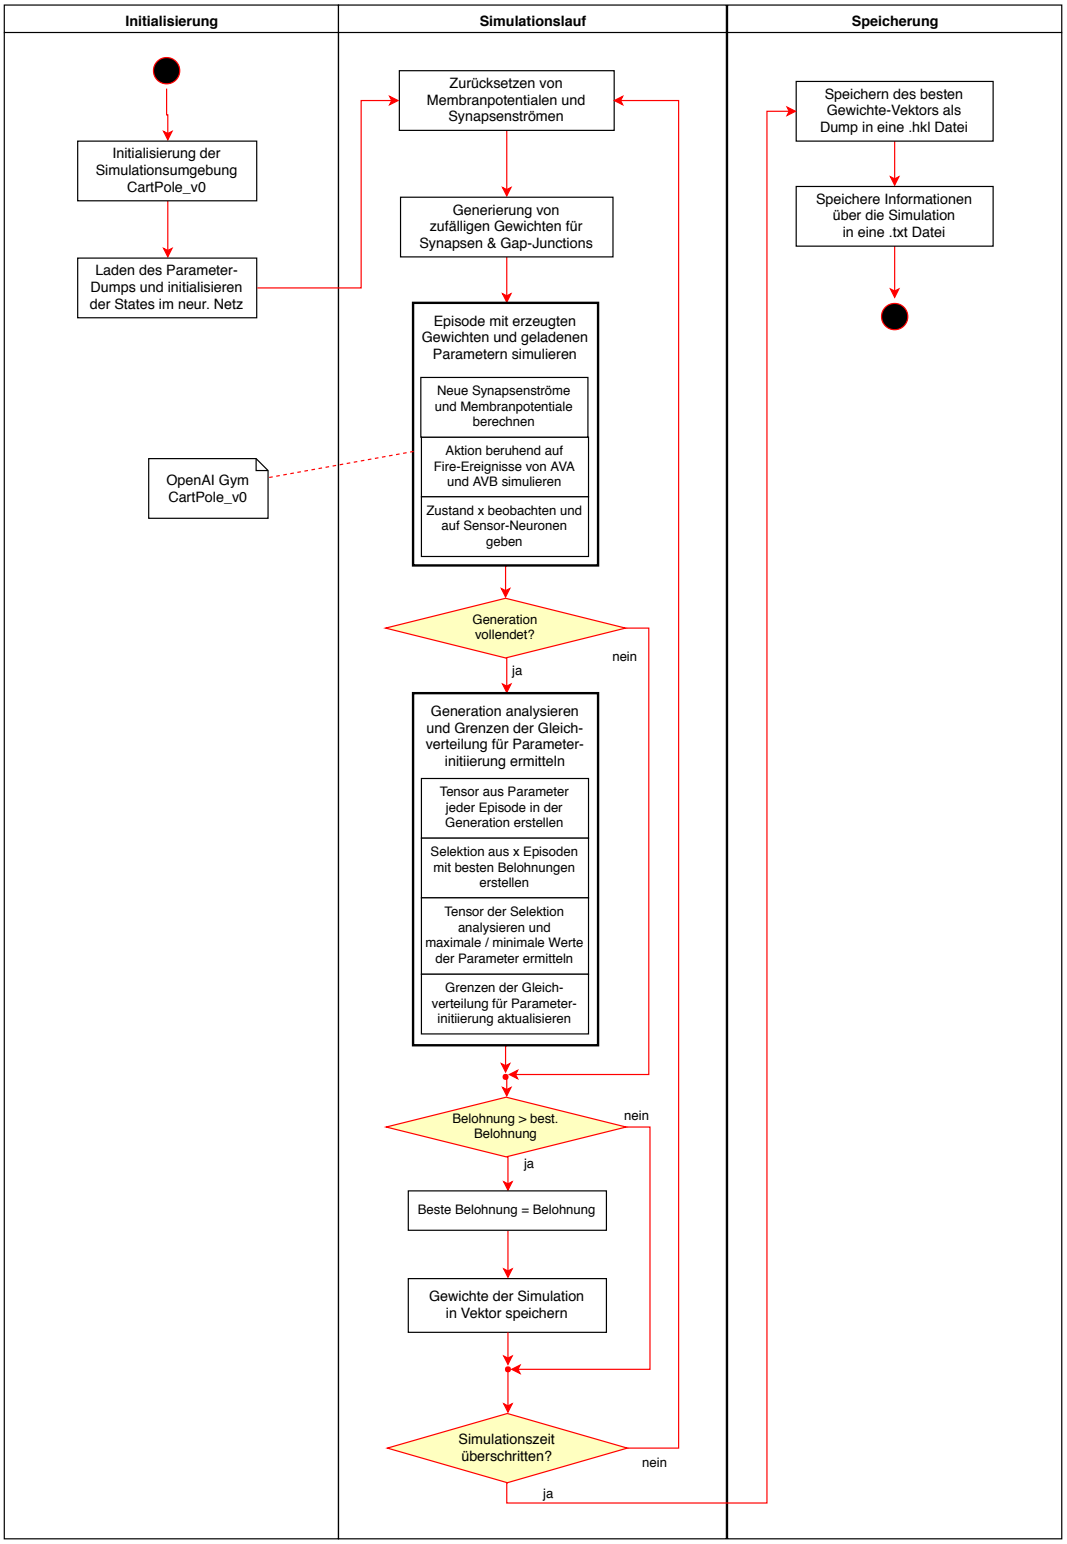

Abb. A.2: UML Diagramm des Algorithmus `Genetic_Algorithm`.

A.3 Weights

Die folgende Abbildung A.3 stellt den genutzten Algorithmus **Weights** qualitativ in einem Programmablaufplan vor.

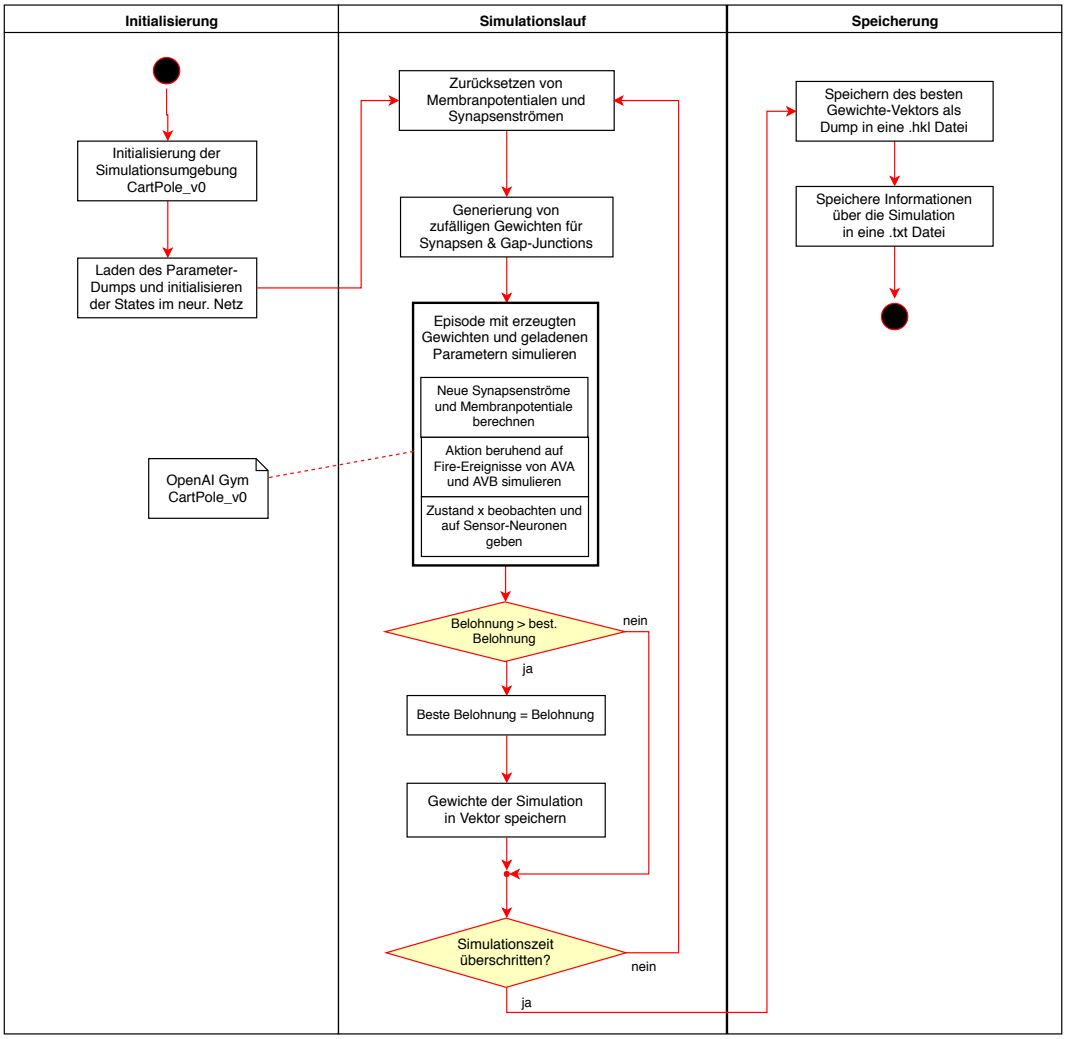

Abb. A.3: UML Diagramm des Algorithmus **Weights**.

Anhang B

Datenblatt Simulator: TW Circuit

Name

TW Circuit

Kurzinfo

Das Programm TW Circuit dient als Simulator des Touch Withdrawal Circuit des Wurms *C. Elegans* [9]. Es kann ein beliebig aufgebautes, neuronales Netz mit biologischem Hintergrund implementiert werden. Dazu wird das LIF - Modell genutzt, um die neuronale Dynamik zu simulieren und Feuer-Events vorherzusagen. Der Output wird auf eine beliebige Simulationsumgebung gegeben, in diesem Beispiel wird OpenAI's CartPole_v0 genutzt. Der Simulator ist OpenSource und kann beliebig erweitert oder verändert werden. Er verfügt darüber hinaus auch über Inspektionsfunktionen sowie gut dokumentierten Code, um Befehle schnell nachzuvollziehen.

Dependencies

- NumPy aus dem SciPy-Package
  Numerische Berechnungen und Matrixoperationen.
- matplotlib aus dem SciPy-Package
  Plots und Grafiken anzeigen und exportieren.
- OpenAI Gym
  Simulationsumgebung CartPole_v0
- hickle
  Performantes Speichern im HDF-5-Format
- os, time, datetime

QR-Code

Dateibaum

TW Circuit

- docs
- information
- modules
  - genetic_algorithm.py
  - inspect.py
  - lif.py
  - parameters.py
  - random_search_v2.py
  - visiualize.py
  - weights.py
- parameter_dumps
- weight_dumps
- main.py

Anhang C
Parameter & Simulationsergebnisse

Nachfolgend werden verschiedene Simulationsläufe mit guten Ergebnissen im Detail in Tabelle C.1 vorgestellt. Dabei wird besonders auf die Parameter und Gewichte des neuronalen Netzes wert gelegt, da diese durch Simulationen gefunden wurden.
Folgende Konvention wird eingehalten, um die Ergebnisse anschaulich darzustellen:
Parameter der Nervenzellen:

$$\boldsymbol{C_m} = \begin{bmatrix} C_{AVA}\, C_{AVD}\, C_{PVC}\, C_{AVB} \end{bmatrix}^T, \tag{C.1}$$

$$\boldsymbol{G_{Leak}} = \begin{bmatrix} G_{AVA}\, G_{AVD}\, G_{PVC}\, G_{AVB} \end{bmatrix}^T, \tag{C.2}$$

$$\boldsymbol{U_{Leak}} = \begin{bmatrix} U_{AVA}\, U_{AVD}\, U_{PVC}\, U_{AVB} \end{bmatrix}^T. \tag{C.3}$$

Parameter der Synapsen und Gap-Junctions werden anhand der Transitionsmatrizen (3.21) und (3.22) aus Abschnitt 3.4 in Vektorschreibweise dargestellt:

$$\boldsymbol{\sigma} = \begin{bmatrix} \sigma_A\, \sigma_B \end{bmatrix}^T = \begin{bmatrix} \sigma_1 \dots \sigma_{16} \end{bmatrix}^T, \tag{C.4}$$

$$\boldsymbol{w} = \begin{bmatrix} w_A\, w_B \end{bmatrix}^T = \begin{bmatrix} w_1 \dots w_{16} \end{bmatrix}^T, \tag{C.5}$$

$$\hat{\boldsymbol{w}} = \begin{bmatrix} \hat{w}_1\, \hat{w}_2 \end{bmatrix}^T. \tag{C.6}$$

Gewichte der Synapsen ($\boldsymbol{\sigma}$, $\boldsymbol{w}$) und Gap-Junctions ($\hat{\boldsymbol{w}}$) werden anhand der Transitionsmatrizen (3.21) und (3.22) aus Abschnitt 3.4 in Vektorschreibweise dargestellt:

$$\boldsymbol{g} = \begin{bmatrix} g_A\, g_B \end{bmatrix}^T = \begin{bmatrix} g_1 \dots g_{18} \end{bmatrix}^T. \tag{C.7}$$

Weitere Parameter und Einheiten sind der Tabelle 4.1 zu entnehmen. In Abbildung C.1 werden den Synapsen des bekannten neuronalen Netzes Nummerierungen hinzugefügt, um die Parameter der Synapsen und Gap-Junctions zuweisen zu können.

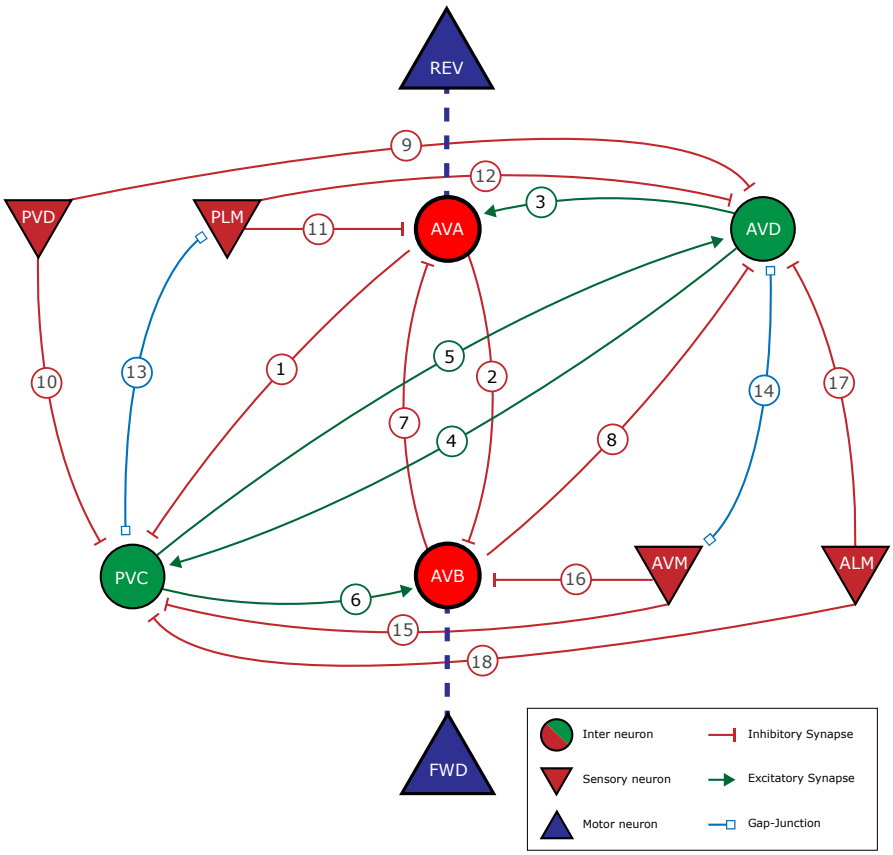

Abb. C.1: Neuronales Netz mit Legende für Gewichte.

Zeitstempel	*Algorithmus*	*Belohnung*	*Simulation (Dauer, Anz.)*	*Parameter*
20180817_01-56-01	`Random-Search` - Parameter	**200**	12h, ca. 1 Mio. Sim.	Parameter der Nervenzellen $\boldsymbol{C_m} = \left[0.01, 0.01, 0.01, 0.01\right]^T$, $\boldsymbol{G_{Leak}} = \left[1.42, 0.63, 1.42, 0.63\right]^T$, $\boldsymbol{U_{Leak}} = \left[-63.2, -62.2, -63.2, -62.2\right]^T$. Parameter der Synapsen & Gap-Junctions $\boldsymbol{\sigma} = \begin{bmatrix}0.16, 0.49, 0.15, 0.29, 0.16, 0.49, 0.15, 0.29,\\ 0.13, 0.39, 0.17, 0.06, 0.13, 0.39, 0.17, 0.06\end{bmatrix}^T$, $\boldsymbol{w} = \begin{bmatrix}0.97, 1.57, 1.48, 1.28, 0.97, 1.57, 1.48, 1.28,\\ 1.71, 1.45, 0.78, 2.84, 1.71, 1.45, 0.78, 2.84\end{bmatrix}^T$, $\hat{\boldsymbol{w}} = \left[1.84, 1.84\right]^T$.
20180817_13-56-01	`Weights` - Gewichte	200	12h, ca. 400.000 Sim.	Gewichte der Synapsen $\boldsymbol{g} = \begin{bmatrix}0.94, 0.96, 0.95, 0.14, 0.94, 0.96, 0.95, 0.14, 0.75,\\ 0.45, 0.54, 0.21, 0.97, 0.75, 0.45, 0.54, 0.21, 0.97\end{bmatrix}^T$.
20180905_14-19-10	`Genetic_Algorithm` - Parameter	200	1:30 Min, ca. 50 Tsd. Sim.	Parameter der Nervenzellen $\boldsymbol{C_m} = \left[0.04, 0.58, 0.58, 0.04\right]^T$, $\boldsymbol{G_{Leak}} = \left[0.75, 0.30, 0.30, 0.75\right]^T$, $\boldsymbol{U_{Leak}} = \left[-58.7, -55.6, -55.6, -58.7\right]^T$. Parameter der Synapsen & Gap-Junctions $\boldsymbol{\sigma} = \begin{bmatrix}0.17, 0.37, 0.42, 0.15, 0, 150.42, 0.37, 0.17,\\ 0.26, 0.27, 0.46, 0.20, 0.20, 0.46, 0.27, 0.26\end{bmatrix}^T$, $\boldsymbol{w} = \begin{bmatrix}0.31, 0.18, 2.45, 0.93, 0, 932.45, 0.18, 0.31,\\ 0.97, 1.21, 1.25, 0.53, 0.53, 1.25, 1.21, 0.97\end{bmatrix}^T$, $\hat{\boldsymbol{w}} = \left[2.40, 2.40\right]^T$.

Tabelle C.1: Simulationsläufe mit guten Ergebnissen

Literaturverzeichnis

1. Brockman G, Cheung V, Pettersson L, Schneider J, Schulman J, Tang J, Zaremba W (2016) Openai gym http://arxiv.org/abs/1606.01540v1
2. Chalfie M, Sulston JE, White JG, Southgate E, Thomson JN, Brenner S (1985) The neural circuit for touch sensitivity in caenorhabditis elegans. The Journal of Neuroscience 5(4):956–964
3. Darwin C (1859) On the Origin of Species by Means of Natural Selection. Murray, London, URL https://www.bibsonomy.org/bibtex/2d70d713c717fb28384fb073c9f6dfbc2/neilernst
4. Goldberg DE (1989) Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley Professional, URL https://www.amazon.com/Genetic-Algorithms-Optimization-Machine-Learning/dp/0201157675?SubscriptionId=AKIAIOBINVZYXZQZ2U3A&tag=chimbori05-20&linkCode=xm2&camp=2025&creative=165953&creativeASIN=0201157675
5. Group TH (2018) Hierarchical data format, version 5. URL http://www.hdfgroup.org/HDF5/
6. Hasani RM, Beneder V, Fuchs M, Lung D, Grosu R (2017) Sim-ce: An advanced simulink platform for studying the brain of caenorhabditis elegans
7. Holland JH (1992) Adaptation in Natural and Artificial Systems. MIT University Press Group Ltd, URL https://www.ebook.de/de/product/2864942/john_h_holland_adaptation_in_natural_and_artificial_systems.html
8. Hunter JD (2007) Matplotlib: A 2d graphics environment. Computing in Science & Engineering 9(3):90–95, DOI 10.1109/mcse.2007.55
9. Lechner M, Grosu R, Hasani RM (2017) Worm-level control through search-based reinforcement learning
10. Lechner M, M Hasani R, Grosu R (2018) Neuronal circuit policies
11. LeCun Y, Bengio Y, Hinton G (2015) Deep learning. Nature 521:436, URL http://dx.doi.org/10.1038/nature14539
12. von Neumann J (1945) First draft of a report on the edvac. Tech. rep.

13. Oliphant TE (2006) A guide to NumPy. Trelgol Publishing USA

14. Rojas R (1996) Theorie der neuronalen Netze: Eine systematische Einführung (Springer-Lehrbuch) (German Edition). Springer, URL https://www.amazon.com/Theorie-neuronalen-Netze-systematische-Springer-Lehrbuch/dp/3540563539?SubscriptionId=0JYN1NVW651KCA56C102&tag=techkie-20&linkCode=xm2&camp=2025&creative=165953&creativeASIN=3540563539

15. Russell S, Norvig P (2016) Artificial Intelligence: A Modern Approach. Always learning, Pearson Higher Education & Professional Group, URL https://books.google.de/books?id=XS9CjwEACAAJ

16. Silver D (2015) Ucl course on reinforcement learning, URL http://www0.cs.ucl.ac.uk/staff/d.silver/web/Teaching.html

17. Strogatz SH (1994) Nonlinear Dynamics And Chaos: With Applications To Physics, Biology, Chemistry And Engineering (Studies in Nonlinearity). Studies in nonlinearity, Perseus Books, URL https://books.google.de/books?id=PHmED2xxrE8C

18. Turing AM (1936) On computable numbers, with an application to the Entscheidungsproblem. Proceedings of the London Mathematical Society 2(42):230–265, URL https://www.cs.virginia.edu/~robins/Turing_Paper_1936.pdf

19. Watkins CJCH, Dayan P (1992) Q-learning. Machine Learning 8(3):279–292, URL https://doi.org/10.1007/BF00992698

20. Wicks SR, Roehrig CJ, Rankin CH (1996) A dynamic network simulation of the nematode tap withdrawal circuit: Predictions concerning synaptic function using behavioral criteria. J Neurosci 16(12):4017, URL http://www.jneurosci.org/content/16/12/4017.abstract

21. Wulfram Gerstner RNLP Werner M Kistler (2014) Neuronal Dynamics From Single Neurons to Networks and Models of Cognition, 1st edn. Cambridge University Press, Cambridge CB2 8BS, United Kingdom

Erklärung

Ich versichere, dass ich die Bachelor-Arbeit

Eine Anwendung des Reinforcement Learning auf biologische neuronale Netze zur Regelung dynamischer Systeme am Beispiel des inversen Pendels

selbständig und ohne unzulässige fremde Hilfe angefertigt habe und dass ich alle von anderen Autoren wörtlich übernommenen Stellen, wie auch die sich an die Gedankengänge anderer Autoren eng anlehnenden Ausführungen, meiner Arbeit besonders gekennzeichnet und die entsprechenden Quellen angegeben habe.

Mir ist bekannt, dass die unter Anleitung entstandene Bachelor-Arbeit, vorbehaltlich anders lautender Vereinbarungen, eine Gruppenleistung darstellt und in die Gesamtforschung der betreuenden Institution eingebunden ist. Daher darf keiner der Miturheber (z.B. Texturheber, gestaltender Projektmitarbeiter, mitwirkender Betreuer) ohne (schriftliches) Einverständnis aller Beteiligten, aufgrund ihrer Urheberrechte, auch Passagen der Arbeit weder kommerziell nutzen noch Dritten zugänglich machen. Insbesondere ist das Arbeitnehmererfindergesetz zu berücksichtigen, in dem eine Vorveröffentlichung patentrelevanter Inhalte verboten wird.

Kiel, 07. September 2018

Jonas Helmut Wilinski